

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HƯNG YÊN



ĐỒ ÁN TỐT NGHIỆP
PHÁT TRIỂN HỆ THỐNG GỢI Ý THỜI TRANG
CÁ NHÂN HÓA DỰA TRÊN HÀNH VI NGƯỜI DÙNG
VÀ DỮ LIỆU THỊ GIÁC

NGÀNH: KHOA HỌC MÁY TÍNH
CHUYÊN NGÀNH: TRÍ TUỆ NHÂN TẠO VÀ KHOA HỌC DỮ LIỆU

SINH VIÊN: BÙI DUY ANH
MÃ SINH VIÊN: 12422002
MÃ LỚP: 12422TN
HƯỚNG DẪN: TS. PHẠM MINH CHUẨN

HƯNG YÊN – 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT HƯNG YÊN

BÙI DUY ANH

PHÁT TRIỂN HỆ THỐNG GỢI Ý THỜI TRANG CÁ NHÂN
HÓA DỰA TRÊN HÀNH VI NGƯỜI DÙNG VÀ DỮ LIỆU
THỊ GIÁC

NGÀNH: KHOA HỌC MÁY TÍNH
CHUYÊN NGÀNH: TRÍ TUỆ NHÂN TẠO VÀ KHOA HỌC DỮ LIỆU

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC

NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ và tên)

TS. Phạm Minh Chuẩn

CHỦ TỊCH HỘI ĐỒNG
(Ký và ghi rõ họ và tên)

PGS. TS. Nguyễn Minh Tiến

HƯNG YÊN - 2026

NHẬN XÉT

Nhận xét của giảng viên hướng dẫn

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

GIẢNG VIÊN HƯỚNG DẪN

LỜI CAM ĐOAN

Em xin cam đoan đồ án “Phát triển hệ thống gợi ý thời trang cá nhân hóa dựa trên hành vi người dùng và dữ liệu thị giác” là kết quả thực hiện của bản thân em dưới sự hướng dẫn của thầy Phạm Minh Chuẩn.

Những phần sử dụng tài liệu tham khảo trong đồ án đã được nêu rõ trong phần tài liệu tham khảo. Các kết quả trình bày trong đồ án và chương trình xây dựng được hoàn toàn là kết quả do bản thân em thực hiện.

Nếu vi phạm lời cam đoan này, em xin chịu hoàn toàn trách nhiệm trước khoa và nhà trường.

Hưng Yên, ngày 31 tháng 05 năm 2026

Sinh viên

Bùi Duy Anh

LỜI CẢM ƠN

Trước hết, em xin bày tỏ lòng biết ơn sâu sắc đến Bộ môn Khoa học Máy tính, Khoa Công nghệ Thông tin, Trường Đại học Sư phạm Kỹ thuật Hưng Yên đã tạo mọi điều kiện thuận lợi để em hoàn thành đồ án tốt nghiệp này. Sự hỗ trợ tận tình từ Nhà trường là nguồn động lực lớn giúp em thực hiện đề tài một cách thuận lợi.

Em đặc biệt xin gửi lời tri ân chân thành đến Thầy TS. Phạm Minh Chuẩn – người hướng dẫn trực tiếp của em. Xin cảm ơn Thầy đã tận tâm chỉ bảo, đồng hành và dành thời gian quý báu để định hướng, góp ý chi tiết trong suốt quá trình thực hiện đồ án. Những lời động viên kịp thời và kinh nghiệm sâu sắc của Thầy đã giúp em vượt qua nhiều khó khăn để hoàn thiện đề tài này.

Em cũng trân trọng cảm ơn các Thầy, Cô trong Khoa Công nghệ Thông tin và Trường Đại học Sư phạm Kỹ thuật Hưng Yên, đặc biệt là PGS. TS. Nguyễn Văn Hậu, PGS. TS. Nguyễn Minh Tiến, PGS. TS. Vũ Khánh Quý, đã truyền đạt những kiến thức nền tảng quý giá và luôn sẵn sàng hỗ trợ em. Sự tận tụy giảng dạy của quý Thầy Cô đã trang bị cho em hành trang vững chắc để thực hiện đề tài “Phát triển hệ thống gợi ý thời trang cá nhân hóa dựa trên hành vi người dùng và dữ liệu thị giác”.

Mặc dù đã nỗ lực hết mình, song với kiến thức và kinh nghiệm còn hạn chế, đồ án khó tránh khỏi những thiếu sót. Em rất mong nhận được sự chỉ dẫn, góp ý quý báu từ các Thầy, Cô để em không ngừng hoàn thiện bản thân trong học tập và nghiên cứu sau này.

Một lần nữa, em xin chân thành cảm ơn!

MỤC LỤC

NHẬN XÉT	3
LỜI CAM ĐOAN	4
LỜI CẢM ƠN	5
MỤC LỤC	6
DANH MỤC CÁC THUẬT NGỮ	9
DANH MỤC CÁC BẢNG, BIỂU	11
DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ	12
CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI	13
1.1 Lý do chọn đề tài.....	13
1.2 Mục tiêu của đề tài	15
1.2.1. Mục tiêu tổng quát	15
1.2.2. Mục tiêu cụ thể.....	16
1.3 Giới hạn và phạm vi của đề tài.....	16
1.3.1. Đối tượng nghiên cứu	16
1.3.2. Phạm vi nghiên cứu.....	17
1.4 Nội dung thực hiện.....	18
1.5 Phương pháp tiếp cận.....	18
CHƯƠNG 2: TỔNG QUAN VỀ CÁC THUẬT TOÁN, MÔ HÌNH TRONG HỆ THỐNG GỢI Ý THỜI TRANG.....	19
2.1 Kỹ thuật trích xuất đặc trưng thị giác và văn bản	19
2.1.1. VGG-19.....	19
2.1.2. CLIP (Contrastive Language-Image Pre-training).....	22
2.1.3. Sentence-Transformers cho đặc trưng văn bản.....	25
2.2 Các phương pháp gợi ý trong hệ thống.....	29
2.2.1. ELFMImproved.....	30
2.2.2. Denoising Autoencoder (DAE).....	33

2.2.3. Reciprocal Rank Fusion (RRF)	38
2.2.4. Bốn phương pháp gợi ý trong đề tài	43
2.3 Các chỉ số đánh giá mô hình	44
2.3.1. Precision@K	44
2.3.2. Recall@K	45
2.3.3. Accuracy@K (Hit Rate@K)	45
2.4 Tổng kết chương 2	46
CHƯƠNG 3: XÂY DỰNG MÔ HÌNH VÀ HỆ THỐNG GỢI Ý THỜI TRANG...	47
3.1 Giới thiệu bài toán.....	47
3.2 Dữ liệu.....	47
3.2.1. Nguồn dữ liệu.....	47
3.2.2. Phân loại sản phẩm.....	48
3.2.3. Quy trình xử lý dữ liệu.....	49
3.2.4. Chuẩn bị dữ liệu cho từng mô hình.....	49
3.3 Huấn luyện mô hình ELFMImproved.....	50
3.3.1. Thiết lập tham số	50
3.3.2. Quá trình huấn luyện.....	50
3.3.3. Kết quả huấn luyện.....	51
3.4 Huấn luyện các mô hình Denoising Autoencoder	52
3.4.1. Thiết lập tham số chung	52
3.4.2. Quá trình huấn luyện.....	52
3.4.3. Kết quả huấn luyện các DAE	53
3.5 Xây dựng và đánh giá các mô hình Hybrid	54
3.5.1. Bốn phương pháp Hybrid.....	54
3.5.2. Quá trình kết hợp Hybrid bằng RRF	54
3.5.3. Thiết lập thực nghiệm đánh giá.....	55

3.5.4. Kết quả thực nghiệm	55
3.5.5. Phân tích kết quả	56
3.6 Xây dựng hệ thống gợi ý thời trang	57
3.6.1. Thiết kế giao diện.....	57
3.6.2. Backend.....	62
3.6.3. Luồng hoạt động	63
3.6.4. Triển khai	65
3.6.5. Tổng kết chương 3	67
KẾT LUẬN	69
TÀI LIỆU THAM KHẢO	72

DANH MỤC CÁC THUẬT NGỮ

STT	Từ viết tắt	Cụm từ tiếng anh	Diễn giải
1	AE	Autoencoder	Mô hình tự mã hóa, học biểu diễn nén của dữ liệu
2	BCE	Binary Cross Entropy	Hàm mất mát nhị phân, dùng cho bài toán phân loại hai lớp
3	CBF	Content-based Filtering	Lọc theo nội dung, gợi ý dựa trên đặc trưng sản phẩm
4	CF	Collaborative Filtering	Lọc cộng tác, gợi ý dựa trên hành vi người dùng
5	CLIP	Contrastive Language-Image Pre-training	Mô hình đa phương thức học không gian embedding chung cho ảnh và văn bản
6	CNN	Convolutional Neural Network	Mạng nơ-ron tích chập, chuyên xử lý dữ liệu ảnh
7	DAE	Denoising Autoencoder	Autoencoder khử nhiễu, học tái tạo dữ liệu từ đầu vào bị nhiễu
8	ELFM	Extended Latent Factor Model	Mô hình nhân tử tiềm ẩn mở rộng cho ba loại sản phẩm
9	FC	Fully Connected	Tầng kết nối đầy đủ trong mạng nơ-ron
10	GNN	Graph Neural Network	Mạng nơ-ron đồ thị, xử lý dữ liệu dạng đồ thị
11	LFM	Local Factor Model	Mô hình nhân tử cục bộ, học tương tác giữa các item
12	LMM	Large Multimodal Model	Mô hình đa phương thức lớn
13	MLP	Multi-Layer Perceptron	Mạng nơ-ron truyền thẳng nhiều tầng

14	MSE	Mean Squared Error	Sai số bình phương trung bình, hàm mất mát cho bài toán hồi quy
15	NCF	Neural Collaborative Filtering	Lọc cộng tác dựa trên mạng nơ-ron
16	NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
17	RRF	Reciprocal Rank Fusion	Kỹ thuật kết hợp thứ hạng dựa trên nghịch đảo
18	SGD	Stochastic Gradient Descent	Thuật toán tối ưu gradient ngẫu nhiên
19	ViT	Vision Transformer	Kiến trúc Transformer cho xử lý ảnh
20	VGG	Visual Geometry Group	Kiến trúc CNN sâu với kernel 3x3 xuyên suốt
21	Conv1D	1-Dimensional Convolution	Tầng tích chập 1 chiều, dùng cho dữ liệu chuỗi hoặc vector đặc trưng
22	ELFMImproved	Improved Extended Latent Factor Model	Phiên bản cải tiến của ELFM với bias, dropout, Adam, negative sampling 4:1
23	ReLU	Rectified Linear Unit	Hàm kích hoạt phi tuyến, $f(x) = \max(0, x)$
24	SQL	Structured Query Language	Ngôn ngữ truy vấn có cấu trúc, dùng để quản lý cơ sở dữ liệu
25	VGG-19	Visual Geometry Group 19-layer	Phiên bản VGG với 19 tầng có trọng số (16 tích chập + 3 fully connected)

DANH MỤC CÁC BẢNG, BIỂU

Bảng 2. 1 So sánh VGG-19 và CLIP ViT-B/32.....	25
Bảng 2. 2 Cải tiến của ELFMImproved so với LFM gốc	31
Bảng 2. 3 Ba biến thể Denoising Autoencoder	36
Bảng 2. 4 Bốn phương pháp gợi ý được triển khai	43
Bảng 2. 5 Tổng hợp các chỉ số đánh giá	46
Bảng 3. 1 Các tệp dữ liệu đầu vào	47
Bảng 3. 2 Kết quả phân loại sản phẩm.....	48
Bảng 3. 3 Kết quả xử lý dữ liệu	49
Bảng 3. 4 Cấu trúc dữ liệu cho từng biến thể DAE	50
Bảng 3. 5 Tham số huấn luyện ELFMImproved	50
Bảng 3. 6 Kết quả huấn luyện ELFMImproved.....	51
Bảng 3. 7 Tham số huấn luyện chung cho các DAE.....	52
Bảng 3. 8 Kết quả huấn luyện ba biến thể DAE	53
Bảng 3. 9 Bốn phương pháp gợi ý được triển khai	54
Bảng 3. 10 Cấu hình thực nghiệm đánh giá	55
Bảng 3. 11 Kết quả của bốn phương pháp gợi ý	55
Bảng 3. 12 Nguyên nhân thành công/thất bại của các phương pháp	56
Bảng 3. 13 Biến màu chính trong giao diện StyleAI	61
Bảng 3. 14 Các module backend và chức năng	62

DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ

Hình 2. 1 Kiến trúc mạng VGG-19	20
Hình 2. 2 Kiến trúc mô hình CLIP với hai nhánh Image Encoder và Text Encoder	24
Hình 2. 3 Kiến trúc mô hình Sentence-Transformers với siamese network	27
Hình 2. 4 Mô hình ELFMImproved học tương tác giữa top, bottom và shoe	30
Hình 2. 5 Kiến trúc Denoising Autoencoder cho bài toán gợi ý giày	35
Hình 2. 6 Quy trình Reciprocal Rank Fusion cho hệ thống gợi ý phối đồ	40
Hình 2. 7 Kiến trúc tổng thể hệ thống gợi ý phối đồ đa phương thức	44
Hình 3. 1 Cấu trúc bộ dữ liệu Amazon Fashion.....	48
Hình 3. 2 Giao diện trang đăng nhập (cột trái giới thiệu, cột phải form login)	58
Hình 3. 3 Giao diện trang khách hàng (hai panel chọn Top và Bottom)	59
Hình 3. 4 Giao diện hiển thị kết quả gợi ý giày (danh sách top-K)	59
Hình 3. 5 Giao diện trang Staff	60
Hình 3. 6 Giao diện trang Admin.....	61

CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI

Chương này trình bày tổng quan về đề tài "Phát triển hệ thống gợi ý thời trang cá nhân hóa dựa trên hành vi người dùng và dữ liệu thị giác", bao gồm lý do chọn đề tài, mục tiêu nghiên cứu, phạm vi, ý nghĩa khoa học và thực tiễn, nội dung thực hiện, cùng phương pháp tiếp cận.

1.1 Lý do chọn đề tài

Trong bối cảnh thương mại điện tử và thời trang số phát triển bùng nổ, các nền tảng như Amazon Fashion, Shopee, Zalo, ASOS đã trở thành kênh mua sắm chính của hàng triệu người dùng. Mỗi ngày, hàng nghìn sản phẩm thời trang mới được đăng tải, tạo ra khối lượng dữ liệu khổng lồ. Tuy nhiên, sự đa dạng này khiến người dùng gặp khó khăn trong việc lựa chọn trang phục phối hợp phù hợp với sở thích và phong cách cá nhân do tình trạng quá tải thông tin.

Khác với gợi ý phim hoặc nhạc – nơi sản phẩm chỉ cần phù hợp với sở thích người dùng – gợi ý thời trang đặt ra bài toán khó hơn nhiều: cần đảm bảo tính tương thích về mặt thị giác giữa các sản phẩm (áo, quần, giày). Một chiếc áo đẹp có thể không hợp với một chiếc quần cụ thể, và một bộ outfit hoàn chỉnh cần được gợi ý một cách hài hòa về mặt thẩm mỹ.

Các phương pháp gợi ý truyền thống như lọc cộng tác (Collaborative Filtering) chỉ dựa trên lịch sử tương tác người dùng – sản phẩm, trong khi lọc theo nội dung (Content-based Filtering) chỉ dựa trên metadata. Cả hai đều chưa giải quyết được bài toán tương thích thị giác giữa các sản phẩm. Chính vì vậy, đề tài này hướng đến xây dựng một hệ thống gợi ý phối đồ hoàn chỉnh (Outfit Coordination), tập trung giải quyết bài toán "Complete the Look": khi người dùng đã chọn Top (áo) và Bottom (quần), hệ thống sẽ gợi ý Shoe (giày) phù hợp nhất về mặt thẩm mỹ và phong cách.

Hệ thống được phát triển kết hợp hai hướng tiếp cận chính. Thứ nhất là User Behavior (hành vi người dùng) thông qua collaborative filtering trên dữ liệu tương tác also_bought. Thứ hai là Visual & Textual Clothing Style sử dụng đa phương thức (multimodal) gồm đặc trưng hình ảnh và mô tả văn bản. Mục tiêu cốt lõi là chuyển từ

recommendation sản phẩm đơn lẻ sang recommendation phối đồ hoàn chỉnh – một xu hướng quan trọng trong lĩnh vực Fashion Recommender Systems hiện nay.

Về mô hình, ELFMImproved được đề xuất như một cải tiến từ mô hình Local Factor Models. Cụ thể, ELFMImproved sử dụng embedding dimension là 100, công thức tính điểm được xác định là $r = (p1 \cdot p2) + (p2 \cdot p3) + (p1 \cdot p3) + b1 + b2 + b3$. Mô hình áp dụng dropout 0.1 và sử dụng bias cho từng item, đồng thời huấn luyện với negative sampling tỷ lệ 4:1.

Về đặc trưng đa phương thức, Visual Features được khai thác từ hai mô hình: VGG-19 cho vector 4096 chiều và CLIP cho vector 512 chiều. Bên cạnh đó, Text Features được trích xuất bằng Sentence-Transformers all-MiniLM-L6-v2 cho vector 384 chiều từ title sản phẩm.

Một điểm mới trong hệ thống là sử dụng Denoising Autoencoders (DAE) với ý tưởng mask shoe và reconstruct từ top + bottom. Ba biến thể DAE được triển khai: VGG-DAE dùng Conv1D với input 12,288 chiều; CLIP-DAE dùng MLP với input 1,536 chiều; và Text-DAE dùng MLP với input 1,152 chiều.

Để đánh giá hiệu quả, bốn phương pháp gợi ý được triển khai và so sánh: (1) LFM only – chỉ sử dụng ELFM embeddings; (2) Paper Hybrid (VGG) – kết hợp ELFM với VGG-DAE; (3) CLIP Hybrid – kết hợp ELFM với CLIP-DAE; (4) CLIP+Text Hybrid – kết hợp ELFM với CLIP-DAE và Text-DAE, đây là mô hình cho kết quả tốt nhất. Kỹ thuật kết hợp ranking được sử dụng là Reciprocal Rank Fusion (RRF).

Nguồn dữ liệu được sử dụng là Amazon Clothing, Shoes & Jewelry dataset – một trong những dataset lớn và phổ biến nhất trong lĩnh vực fashion recommendation. Dữ liệu bao gồm triplets.csv với 2,669 triplets gốc (các cột: top, bottom, shoe); meta_Clothing_Shoes_and_Jewelry.json với khoảng 1.5 triệu sản phẩm dạng JSON Lines chứa thông tin title, categories, imageUrl, related (also_bought, also_viewed...); image_features.npy với 2,202 items được trích xuất bằng VGG-19, mỗi vector có 4096 chiều; và clip_embeddings.npy với 2,202 items được trích xuất bằng CLIP ViT-B-32, mỗi vector có 512 chiều.

Quá trình tiền xử lý bao gồm ba bước quan trọng. Thứ nhất, phân loại sản phẩm thành 3 nhóm chính (Tops, Bottoms, Shoes) bằng phương pháp rule-based. Thứ hai, tăng cường dữ liệu (Data Augmentation) sử dụng quan hệ also_bought để sinh thêm

triplets, đưa tổng số triplets từ 2,669 lên 324,418 mẫu. Thứ ba, chỉ giữ lại 2,202 items có đầy đủ features để đảm bảo chất lượng.

Về thực nghiệm, tập dữ liệu được chia theo tỷ lệ 90/10 trên triplets. Candidate shoes được chọn gồm 300 mẫu (1 ground truth + 299 random). Các chỉ số đánh giá bao gồm Precision@K, Recall@K, Hit Rate@K với $K = 10, 15, 20$ trên 200 test cases. Kết quả đạt được cho thấy mô hình CLIP+Text Hybrid cho kết quả vượt trội với Hit Rate @10 đạt 79,0%, @15 đạt 84,5%, @20 đạt 85,5%. Trong khi đó, phương pháp sử dụng VGG cho kết quả thấp hơn đáng kể (chỉ khoảng 5-7%), nguyên nhân chính được xác định là do VGG features 4096 chiều quá cao, dẫn đến DAE reconstruct kém với cosine similarity chỉ khoảng 0,326.

Những đóng góp chính của đề tài bao gồm: cải tiến mô hình ELFM thành ELFMImproved; xây dựng hệ thống multimodal hybrid kết hợp 3 loại embedding; áp dụng và so sánh nhiều biến thể recommendation; phân tích sâu nguyên nhân thất bại của VGG-DAE; và tăng cường dữ liệu hiệu quả từ quan hệ also_bought.

Do đó, đề tài được lựa chọn nhằm:

- Xây dựng một hệ thống gợi ý phối đồ hoàn chỉnh giải quyết bài toán "Complete the Look"
- Kết hợp cả hai hướng tiếp cận: hành vi người dùng và đặc trưng thị giác
 - văn bản
- Nâng cao độ chính xác của hệ thống thông qua việc kết hợp nhiều loại đặc trưng và kỹ thuật ranking
- So sánh đánh giá nhiều biến thể mô hình để rút ra bài học cho các phát triển tiếp theo

Kết quả không chỉ có giá trị học thuật trong lĩnh vực Hệ thống gợi ý và Thị giác máy tính, mà còn có tiềm năng ứng dụng cao trong thương mại điện tử thời trang, trợ lý ảo phối đồ, và các nền tảng bán lẻ trực tuyến.

1.2 Mục tiêu của đề tài

1.2.1. Mục tiêu tổng quát

Xây dựng một hệ thống khuyến nghị phối đồ thời trang hiệu quả, cung cấp gợi ý chính xác về giày (shoe) khi người dùng đã chọn áo (top) và quần (bottom), dựa trên sự

kết hợp giữa hành vi người dùng và đặc trưng đa phương thức (hình ảnh và văn bản), ứng dụng học máy và học sâu.

1.2.2. Mục tiêu cụ thể

- Nghiên cứu và phân tích các phương pháp khuyến nghị: lọc cộng tác (Collaborative Filtering), lọc theo nội dung (Content-based Filtering), hybrid recommendation, Local Factor Models (LFM), Denoising Autoencoder (DAE), và kỹ thuật kết hợp ranking (Reciprocal Rank Fusion – RRF).
- Thu thập, tiền xử lý và phân tích dữ liệu thời trang từ tập dữ liệu Amazon Clothing, Shoes & Jewelry, bao gồm 2.669 triplets gốc (top, bottom, shoe), 1.5 triệu sản phẩm dạng JSON Lines và các đặc trưng đã trích xuất (VGG-19, CLIP). Thực hiện phân loại sản phẩm thành ba nhóm (Tops, Bottoms, Shoes) bằng rule-based và tăng cường dữ liệu từ quan hệ also_bought để đạt 324.418 triplets.
- Xây dựng, huấn luyện và đánh giá mô hình dựa trên các chỉ số Precision@K, Recall@K, Hit Rate@K (với $K = 10, 15, 20$). So sánh 4 biến thể mô hình: LFM only, VGG Hybrid, CLIP Hybrid, và CLIP+Text Hybrid.
- Triển khai hệ thống gợi ý phối đồ với khả năng: đầu vào là top và bottom, đầu ra là danh sách giày được gợi ý theo thứ tự phù hợp. Tích hợp các đặc trưng thị giác (VGG-19, CLIP) và đặc trưng văn bản (Sentence-Transformers) trong cùng một pipeline.
- Đảm bảo hệ thống giải quyết bài toán "Complete the Look" và tối ưu hóa chất lượng gợi ý thông qua phân tích nguyên nhân thành công/thất bại của từng loại đặc trưng (đặc biệt là lý do VGG-19 cho hiệu suất kém do số chiều quá cao).

1.3 Giới hạn và phạm vi của đề tài

1.3.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu: Hệ thống khuyến nghị phối đồ thời trang, tập trung vào bài toán "Complete the Look" (gợi ý giày khi biết áo và quần), sử dụng dữ liệu từ Amazon Clothing, Shoes & Jewelry dataset (bao gồm triplets top – bottom – shoe, thông

tin sản phẩm dạng JSON, đặc trưng hình ảnh VGG-19 và CLIP, cùng đặc trưng văn bản từ title sản phẩm).

1.3.2. Phạm vi nghiên cứu

- **Phạm vi phương pháp:** Nghiên cứu bốn phương pháp gợi ý:
 - + LFM only: Gợi ý dựa trên mô hình ELFMImproved (cải tiến từ Local Factor Models) sử dụng embedding và tương tác 3 chiều giữa top, bottom, shoe.
 - + VGG Hybrid: Kết hợp ELFMImproved với Denoising Autoencoder trên đặc trưng thị giác VGG-19 (4096 chiều).
 - + CLIP Hybrid: Kết hợp ELFMImproved với Denoising Autoencoder trên đặc trưng thị giác CLIP (512 chiều).
 - + CLIP+Text Hybrid: Kết hợp ELFMImproved với Denoising Autoencoder trên cả đặc trưng CLIP và đặc trưng văn bản từ title sản phẩm (384 chiều).
- **Phạm vi dữ liệu:** Chỉ sử dụng 2.202 sản phẩm có đầy đủ features (VGG-19, CLIP) từ bộ dữ liệu Amazon Clothing, Shoes & Jewelry. Ba loại sản phẩm được xem xét là Tops, Bottoms và Shoes. Các sản phẩm khác (phụ kiện, túi xách, mũ...) nằm ngoài phạm vi nghiên cứu.
- **Phạm vi không gian:** Nghiên cứu được thực hiện trong môi trường học thuật, với tiềm năng ứng dụng thực tế trên các nền tảng thương mại điện tử thời trang và trợ lý ảo phối đồ.
- **Phạm vi thời gian:** Nghiên cứu được thực hiện từ năm 2024 đến tháng 5/2026.
- **Ý nghĩa khoa học:** Nâng cao chất lượng khuyến nghị phối đồ thông qua việc kết hợp hành vi người dùng (collaborative filtering) và đặc trưng đa phương thức (hình ảnh và văn bản), đặc biệt với CLIP và Denoising Autoencoder.
- **Ý nghĩa thực tiễn:** Cá nhân hóa trải nghiệm phối đồ thời trang, hỗ trợ người dùng lựa chọn giày phù hợp với bộ trang phục đã chọn, giảm tình trạng quá tải thông tin trong mua sắm trực tuyến.

1.4 Nội dung thực hiện

- Trình bày lý do lựa chọn đề tài, mục tiêu và phạm vi nghiên cứu của hệ thống gợi ý phối đồ thời trang giải quyết bài toán "Complete the Look".
- Phân tích, tiền xử lý dữ liệu từ Amazon Clothing, Shoes & Jewelry dataset: phân loại sản phẩm thành ba nhóm Tops, Bottoms, Shoes bằng rule-based; tăng cường dữ liệu từ quan hệ also_bought (từ 2.669 lên 324.418 triplets); chuẩn hóa và trích xuất đặc trưng hình ảnh (VGG-19, CLIP) cùng đặc trưng văn bản (Sentence-Transformers).
- Xây dựng bốn mô hình khuyến nghị: LFM only, VGG Hybrid, CLIP Hybrid và CLIP+Text Hybrid (mô hình kết hợp đầy đủ).
- Đánh giá hiệu suất mô hình bằng các chỉ số Precision@K, Recall@K và Hit Rate@K với K = 10, 15, 20 trên 200 test cases.
- Triển khai pipeline gợi ý hoàn chỉnh: đầu vào là top và bottom, đầu ra là danh sách giày được gợi ý theo thứ tự phù hợp, sử dụng kỹ thuật kết hợp ranking Reciprocal Rank Fusion (RRF).

1.5 Phương pháp tiếp cận

- Nghiên cứu lý thuyết: Phân tích tài liệu về hệ thống khuyến nghị thời trang, các thuật toán liên quan đến Local Factor Models, Denoising Autoencoder, đặc trưng đa phương thức (VGG, CLIP, Sentence-Transformers) và kỹ thuật kết hợp ranking.
- Thực nghiệm: Thu thập, tiền xử lý dữ liệu Amazon Clothing, Shoes & Jewelry; xây dựng, huấn luyện và đánh giá bốn mô hình trên tập dữ liệu đã được tăng cường (324.418 triplets). Tỷ lệ chia train/test là 90/10.
- Đánh giá: So sánh hiệu suất các mô hình dựa trên các chỉ số Precision@K, Recall@K, Hit Rate@K. Phân tích nguyên nhân thành công (CLIP, text embeddings) và thất bại (VGG-4096 chiều gây reconstruct kém).
- Triển khai: Thiết kế pipeline gợi ý hoàn chỉnh cho phép nhận đầu vào là top và bottom, trích xuất đặc trưng tương ứng, tính toán điểm số qua ELFMImproved và các DAE, sau đó kết hợp ranking bằng RRF để xuất ra danh sách giày được gợi ý.

CHƯƠNG 2: TỔNG QUAN VỀ CÁC THUẬT TOÁN, MÔ HÌNH TRONG HỆ THỐNG GỢI Ý THỜI TRANG

Chương này trình bày tổng quan về các thuật toán và mô hình được sử dụng trong hệ thống gợi ý thời trang, tập trung vào các kỹ thuật trích xuất đặc trưng thị giác và các phương pháp gợi ý chính. Nội dung phân tích ưu điểm, nhược điểm và cơ sở lý thuyết của từng phương pháp, đồng thời giới thiệu các chỉ số đánh giá hiệu suất để làm cơ sở cho việc xây dựng và triển khai hệ thống.

2.1 Kỹ thuật trích xuất đặc trưng thị giác và văn bản

Trích xuất đặc trưng thị giác và văn bản đóng vai trò quan trọng trong hệ thống gợi ý thời trang, đặc biệt trong việc đánh giá độ tương thích về mặt thẩm mỹ giữa các sản phẩm (áo, quần, giày) cũng như khai thác thông tin mô tả từ tiêu đề sản phẩm. Khác với các bài toán gợi ý truyền thống chỉ dựa vào ID sản phẩm hoặc ma trận tương tác, gợi ý thời trang đòi hỏi hệ thống phải hiểu được đặc tính thị giác như màu sắc, họa tiết, kiểu dáng, chất liệu, cũng như ngữ nghĩa từ mô tả sản phẩm. Do đó, việc lựa chọn kỹ thuật trích xuất đặc trưng phù hợp có ảnh hưởng trực tiếp đến chất lượng của toàn bộ hệ thống. Các kỹ thuật chính được sử dụng trong đề tài bao gồm VGG-19, CLIP và Sentence-Transformers.

2.1.1. VGG-19


VGG-19 là một kiến trúc mạng nơ-ron tích chập (Convolutional Neural Network – CNN) được phát triển bởi nhóm nghiên cứu Visual Geometry Group tại Đại học Oxford. Đây là một trong những mô hình tiên phong trong việc chứng minh rằng độ sâu của mạng là yếu tố then chốt để đạt được hiệu suất cao trong các bài toán thị giác máy tính. VGG-19 có tổng cộng 19 tầng có trọng số, bao gồm 16 tầng tích chập (convolutional layer) và 3 tầng kết nối đầy đủ (fully connected layer). Điểm đặc trưng nổi bật của VGG-19 là sự nhất quán trong thiết kế: toàn bộ các tầng tích chập đều sử dụng bộ lọc (kernel) kích thước 3×3 và tầng gộp (pooling) kích thước 2×2 , tạo thành các khối convolution liên tiếp trước khi qua tầng gộp. Sự lặp lại đơn giản này giúp mạng dễ dàng mở rộng độ sâu mà không làm tăng độ phức tạp của từng tầng, đồng thời vẫn đảm bảo khả năng học được các đặc trưng từ đơn giản đến phức tạp.

– Kiến trúc

Bảng 2. 1 Kiến trúc chi tiết của VGG-19

Thành phần	Mô tả chi tiết
Đầu vào	Ảnh màu kích thước $224 \times 224 \times 3$ (3 kênh RGB)
Khối tích chập 1	$2 \times [\text{Conv3-64}] + \text{MaxPooling} (2 \times 2)$
Khối tích chập 2	$2 \times [\text{Conv3-128}] + \text{MaxPooling} (2 \times 2)$
Khối tích chập 3	$4 \times [\text{Conv3-256}] + \text{MaxPooling} (2 \times 2)$
Khối tích chập 4	$4 \times [\text{Conv3-512}] + \text{MaxPooling} (2 \times 2)$
Khối tích chập 5	$4 \times [\text{Conv3-512}] + \text{MaxPooling} (2 \times 2)$
Tầng Fully Connected	$\text{FC1} (4096) \rightarrow \text{FC2} (4096) \rightarrow \text{FC3} (1000)$
Đầu ra	1000 lớp tương ứng với 1000 lớp của ImageNet

Trong đó, "Conv3-64" có nghĩa là tầng tích chập với 64 bộ lọc kích thước 3×3 . Sau mỗi tầng tích chập, hàm kích hoạt ReLU (Rectified Linear Unit) được áp dụng để đưa tính phi tuyến vào mô hình. Tầng MaxPooling với kích thước 2×2 giúp giảm một nửa kích thước không gian của đặc trưng, đồng thời tăng khả năng chịu biến dạng và giảm số lượng tham số cần học.



Hình 2. 1 Kiến trúc mạng VGG-19

– **Cơ chế trích xuất đặc trưng**

Đôi với bài toán gợi ý thời trang, không sử dụng đầu ra phân loại cuối cùng (1000 lớp) mà sử dụng đặc trưng trích xuất từ tầng fully connected thứ hai (FC7) – tầng có 4096 nơ-ron. Lý do là tầng này chứa đựng các đặc trưng trừu tượng và giàu ngữ nghĩa nhất mà mô hình học được từ ảnh đầu vào. Vector đặc trưng 4096 chiều này có thể được coi là một "dấu vân tay" số của ảnh, thể hiện các đặc tính thị giác như hình dáng, màu sắc, họa tiết và kết cấu của sản phẩm thời trang.

– **Ưu điểm của VGG-19**

- + Kiến trúc đơn giản, dễ hiểu và dễ triển khai
- + Đã được huấn luyện trước trên tập dữ liệu ImageNet với hàng triệu ảnh, có khả năng tổng quát hóa tốt
- + Các đặc trưng trích xuất được từ VGG-19 đã được chứng minh là hiệu quả trong nhiều tác vụ thị giác khác nhau

– **Nhược điểm của VGG-19**

- + Số lượng tham số rất lớn (khoảng 138 triệu), dẫn đến chi phí tính toán cao
- + Vector đặc trưng có số chiều rất lớn (4096), có thể gây ra hiện tượng "curse of dimensionality" khi kết hợp với các mô hình như Denoising Autoencoder
- + Không được huấn luyện trên dữ liệu thời trang cụ thể, có thể thiếu các đặc trưng đặc thù cho lĩnh vực này

– **Ứng dụng trong đề tài:**

Vector đặc trưng 4096 chiều từ VGG-19 được sử dụng làm biểu diễn thị giác cho mỗi sản phẩm (top, bottom, shoe). Các vector này đã được trích xuất sẵn từ trước và lưu trong file `image_features.npy` cho 2.202 items. Trong quá trình huấn luyện, các vector này được ghép nối với nhau để tạo thành đầu vào cho mô hình VGG-DAE: vector đầu vào là `[f_top, f_bottom, zeros]` với tổng chiều 12.288 (3×4096), và mục tiêu là tái tạo lại `[f_top, f_bottom, f_shoe]`.

Tuy nhiên, như sẽ được phân tích trong phần thực nghiệm, đặc trưng VGG-19 cho thấy hiệu suất không cao trong bài toán này do số chiều quá lớn, dẫn đến mô hình DAE không thể reconstruct tốt (cosine similarity chỉ đạt khoảng 0,326). Đây là lý do đề tài chuyển sang sử dụng CLIP – một mô hình đa phương thức hiện đại hơn với số chiều đặc trưng nhỏ hơn và ngữ nghĩa giàu hơn.

2.1.2. CLIP (Contrastive Language-Image Pre-training)

CLIP là mô hình đa phương thức (multimodal) được phát triển bởi OpenAI, được huấn luyện trên 400 triệu cặp (ảnh, văn bản) thu thập từ internet. Điểm đột phá của CLIP so với các mô hình thị giác truyền thống như VGG-19 là khả năng học được một không gian embedding chung cho cả hình ảnh và ngôn ngữ thông qua kỹ thuật học tương phản (contrastive learning). Điều này có nghĩa là CLIP có thể "hiểu" được mối quan hệ giữa nội dung của một bức ảnh và mô tả văn bản đi kèm, từ đó tạo ra các vector embedding có ngữ nghĩa phong phú và khả năng tổng quát hóa cao trên nhiều tác vụ khác nhau, bao gồm cả phân loại ảnh không có trong tập huấn luyện (zero-shot classification).

– **Nguyên lý hoạt động của CLIP:**

CLIP hoạt động dựa trên ý tưởng học tương phản: trong mỗi batch huấn luyện gồm N cặp (ảnh, text) đúng, mô hình học cách kéo embedding của ảnh và embedding của text đúng lại gần nhau trong không gian vector (tối đa hóa cosine similarity), đồng thời đẩy embedding của ảnh và text sai ra xa nhau (tối thiểu hóa cosine similarity). Cơ chế này giúp CLIP xây dựng được một không gian embedding mà trong đó các cặp ảnh-text có nội dung liên quan sẽ nằm gần nhau, bất kể đó là nội dung gì.

– **Kiến trúc sử dụng: CLIP ViT-B/32**

- + Image Encoder: Vision Transformer (ViT) với patch size 32×32
- + Text Encoder: Transformer
- + Contrastive Learning: Tối đa hóa cosine similarity giữa cặp (ảnh, text) đúng

Bảng 2. 2 Kiến trúc chi tiết của CLIP ViT-B/32

Thành phần	Mô tả chi tiết
Image Encoder	Vision Transformer (ViT) với patch size 32×32 . Ảnh đầu vào (224×224) được chia thành các patch 32×32 , sau đó được đưa qua các tầng Transformer để trích xuất đặc trưng. Kết quả đầu ra là vector embedding 512 chiều.
Text Encoder	Mô hình Transformer (tương tự kiến trúc GPT). Văn bản đầu vào được token hóa, đưa qua các tầng Transformer để trích xuất đặc trưng. Kết quả đầu ra là vector embedding 512 chiều.

Projection Layer	Cả image embedding và text embedding được chiếu qua một tầng linear để đưa về cùng không gian vector có số chiều bằng nhau (512 chiều).
Contrastive Loss	Hàm mất mát được tính dựa trên ma trận tương đồng (similarity matrix) kích thước $N \times N$ giữa N embedding ảnh và N embedding text, với mục tiêu tối đa hóa đường chéo (các cặp đúng).

– Cơ chế học tương phản trong CLIP

Giả sử trong một batch huấn luyện có N cặp (ảnh, text) đúng. CLIP xây dựng một ma trận tương đồng kích thước $N \times N$, trong đó phần tử (i, j) là cosine similarity giữa embedding ảnh thứ i và embedding text thứ j . Mục tiêu của mô hình là làm cho các phần tử trên đường chéo (ảnh i với text i – cặp đúng) có giá trị cao, đồng thời các phần tử ngoài đường chéo (ảnh i với text $j \neq i$ – cặp sai) có giá trị thấp. Hàm mất mát được tính dựa trên cross-entropy loss cho cả hai chiều (ảnh $\rightarrow$ text và text $\rightarrow$ ảnh).

Bảng 2.3 Ưu điểm của CLIP so với các mô hình thị giác truyền thống

Tiêu chí	VGG-19	CLIP ViT-B/32
Số chiều đặc trưng	4096	512
Dữ liệu huấn luyện	ImageNet (1,4 triệu ảnh, 1.000 lớp)	400 triệu cặp (ảnh, text)
Kiến trúc	CNN	Vision Transformer (ViT)
Khả năng ngữ nghĩa	Thấp (chỉ học từ ảnh)	Cao (học từ ảnh + văn bản)
Khả năng zero-shot	Không	Có
Hiệu quả với DAE	Kém (cosine similarity $\sim 0,326$)	Tốt (cosine similarity $\sim 0,921$)

– Ứng dụng trong đề tài

Trong đề tài này, CLIP ViT-B/32 được sử dụng làm bộ trích xuất đặc trưng thị giác thay thế cho VGG-19. Cụ thể, với mỗi sản phẩm (top, bottom, shoe), hệ thống lấy ảnh của sản phẩm, đưa qua Image Encoder của CLIP để thu được vector embedding 512

chiều. Các vector này đã được trích xuất sẵn và lưu trong file clip_embeddings.npy cho 2.202 items. Vector embedding 512 chiều này được sử dụng làm đầu vào cho mô hình CLIP-DAE, với tổng chiều đầu vào là 1.536 (3×512). Nhờ số chiều nhỏ hơn đáng kể so với VGG-19 (512 so với 4096) và ngữ nghĩa giàu hơn, CLIP-DAE đạt hiệu suất vượt trội với cosine similarity lên tới ~0,921, góp phần quan trọng vào thành công của mô hình CLIP+Text Hybrid (đạt Accuracy@10 = 79%).


– Công thức Contrastive Loss:

$$L_{contrastive} = -\frac{1}{N} \sum_{i=1}^N \log \left(\frac{\exp\left(\frac{\text{sim}(I_i, T_i)}{\tau}\right)}{\sum_{j=1}^N \exp\left(\frac{\text{sim}(I_i, T_j)}{\tau}\right)} \right) \quad (2.1)$$

Trong đó:

- I_i : Embedding của ảnh thứ i
- T_i : Embedding của text thứ i
- **sim**: Cosine similarity
- τ : Temperature parameter
- N : Kích thước batch

Vector embedding **512 chiều** từ CLIP ViT-B/32 được sử dụng làm đặc trưng thị giác cho mỗi sản phẩm. Các vector này được lưu trong file clip_embeddings.npy cho 2.202 items.



Hình 2. 2 Kiến trúc mô hình CLIP với hai nhánh Image Encoder và Text Encoder

Bảng 2. 4 So sánh VGG-19 và CLIP ViT-B/32

Tiêu chí	VGG-19	CLIP ViT-B/32
Số chiều đặc trưng	4096	512
Kiến trúc	CNN	Vision Transformer (ViT)
Khả năng ngữ nghĩa	Thấp (chỉ hình ảnh)	Cao (hình ảnh + văn bản)
Dữ liệu huấn luyện	ImageNet (1.4M ảnh)	400M cặp (ảnh, text)
Hiệu suất DAE	Kém (cosine sim ~ 0.326)	Tốt

2.1.3. Sentence-Transformers cho đặc trưng văn bản

Sentence-Transformers là một thư viện chuyên dụng được phát triển để tạo embedding cho câu và văn bản, dựa trên kiến trúc Transformer. Thư viện này ra đời nhằm giải quyết một hạn chế lớn của các mô hình BERT truyền thống: BERT được thiết kế để xử lý các cặp câu đầu vào (ví dụ cho bài toán phân loại hoặc trả lời câu hỏi) nhưng không được tối ưu để tính toán độ tương đồng ngữ nghĩa giữa hàng nghìn câu với nhau. Khi sử dụng BERT nguyên bản, cần phải đưa từng cặp câu vào mô hình để tính toán, dẫn đến độ phức tạp $O(n^2)$ và không khả thi với số lượng câu lớn. Sentence-Transformers khắc phục vấn đề này bằng cách sử dụng kiến trúc siamese network (mạng song sinh) và triplet network (mạng ba), cho phép tính toán embedding cho từng câu độc lập, sau đó sử dụng các phép tính vector đơn giản (như cosine similarity) để xác định độ tương đồng giữa các câu. Điều này giảm độ phức tạp xuống $O(n)$ cho việc tạo embedding và $O(n^2)$ chỉ cho việc tính toán độ tương đồng sau đó, giúp ứng dụng vào các hệ thống gợi ý quy mô lớn trở nên khả thi.

– Mô hình all-MiniLM-L6-v2


Mô hình all-MiniLM-L6-v2 là một biến thể nhẹ (lightweight) của Sentence-Transformers, được thiết kế để cân bằng giữa hiệu suất và tốc độ xử lý. Đây là một trong những mô hình phổ biến nhất trong thư viện Sentence-Transformers nhờ kích thước nhỏ gọn nhưng vẫn duy trì được chất lượng embedding tốt cho hầu hết các tác vụ xử lý ngôn ngữ tự nhiên thông thường. Mô hình này được huấn luyện để ánh xạ câu hoặc đoạn văn bản ngắn (tối đa 256 token) thành một vector embedding có số chiều là 384. Con số 384 chiều được lựa chọn dựa trên sự cân nhắc giữa khả năng biểu diễn thông tin (càng nhiều

chiều càng biểu diễn được nhiều thông tin) và hiệu quả tính toán (càng ít chiều càng nhanh và càng ít nguy cơ overfitting).

– **Nguyên lý hoạt động:**

Sentence-Transformers hoạt động dựa trên ba nguyên lý chính như sau:

- + **Thứ nhất**, sử dụng kiến trúc BERT (Bidirectional Encoder Representations from Transformers) làm nền tảng. BERT là một mô hình ngôn ngữ lớn được huấn luyện trên hàng tỷ từ văn bản, có khả năng hiểu được ngữ cảnh của từ trong câu một cách hai chiều (cả bên trái và bên phải). Khác với các mô hình ngôn ngữ truyền thống chỉ đọc từ trái sang phải, BERT đọc toàn bộ câu cùng lúc, nhờ đó hiểu được mối quan hệ phức tạp giữa các từ. Trong Sentence-Transformers, phần lõi của mô hình là một mạng BERT đã được tiền huấn luyện, đóng vai trò như bộ trích xuất đặc trưng thô từ văn bản đầu vào.
- + **Thứ hai**, áp dụng kỹ thuật siamese network (mạng song sinh). Siamese network là một kiến trúc mạng nơ-ron trong đó hai (hoặc nhiều) đầu vào được xử lý bởi cùng một mô hình với bộ trọng số được chia sẻ hoàn toàn. Đối với Sentence-Transformers, cùng một mô hình BERT (cùng trọng số) được sử dụng để xử lý hai câu đầu vào khác nhau. Sau khi có được embedding của hai câu, một hàm mất mát (thường là triplet loss hoặc multiple negatives ranking loss) được sử dụng để tối ưu hóa khoảng cách cosine giữa các câu có nghĩa tương tự và đẩy xa các câu có nghĩa khác nhau. Quá trình huấn luyện này giúp mô hình học được một không gian embedding mà trong đó khoảng cách giữa các vector phản ánh độ tương đồng về ngữ nghĩa của các câu.
- + **Thứ ba**, đầu ra của mô hình là vector embedding chuẩn hóa (normalized embedding). Sau khi qua các tầng của BERT và một tầng pooling (thường là mean pooling hoặc CLS token pooling), vector embedding thô được chuẩn hóa bằng L2 normalization (chia cho độ dài Euclidean của vector) để đưa vector về độ dài bằng 1. Việc chuẩn hóa này rất quan trọng vì nó đảm bảo rằng phép tính cosine similarity giữa hai embedding (vốn được định nghĩa là tích vô hướng của hai vector khi cả hai đã được chuẩn hóa) có giá trị nằm trong khoảng $[-1, 1]$ và dễ dàng so sánh được giữa các cặp khác nhau.



Hình 2. 3 Kiến trúc mô hình Sentence-Transformers với siamese network

– Ứng dụng trong đề tài

Trong đề tài này, thông tin văn bản được khai thác từ trường **title** (tiêu đề) của mỗi sản phẩm trong bộ dữ liệu Amazon Clothing, Shoes & Jewelry. Title sản phẩm thường là một câu ngắn gọn nhưng chứa đựng nhiều thông tin quan trọng: thương hiệu, loại sản phẩm, chất liệu, phong cách, mùa vụ, v.v. Ví dụ: một sản phẩm có title là "Men's Casual Denim Jeans" cung cấp thông tin về giới tính (Men's), phong cách (Casual), chất liệu (Denim), và loại sản phẩm (Jeans). Một sản phẩm giày có title "Women's Running Shoes" cung cấp thông tin về giới tính (Women's), mục đích sử dụng (Running), và loại sản phẩm (Shoes). Những thông tin này bổ sung cho đặc trưng thị giác, đặc biệt trong các trường hợp ảnh sản phẩm không rõ ràng hoặc khi cần phân biệt các sản phẩm có hình dáng tương tự nhau.

Quy trình xử lý cụ thể như sau: Với mỗi sản phẩm trong bộ dữ liệu, title của sản phẩm (dạng văn bản) được truyền qua mô hình all-MiniLM-L6-v2 để thu được vector embedding có 384 chiều. Không cần bất kỳ tiền xử lý phức tạp nào (như loại bỏ stop words, stemming, lemmatization) vì mô hình Transformer đã được huấn luyện để tự động học các đặc trưng ngôn ngữ từ văn bản thô. Vector embedding này sau đó được lưu lại và sử dụng làm đầu vào cho mô hình Text-DAE, với tổng chiều đầu vào là 1.152 (3×384) khi ghép đặc trưng của top, bottom và vùng trống cho shoe.

– **Ưu điểm của Sentence-Transformers**

- + **Thứ nhất**, kích thước embedding nhỏ (384 chiều). So với VGG-19 (4096 chiều) hay CLIP (512 chiều), embedding văn bản từ Sentence-Transformers có số chiều khiêm tốn nhất. Điều này giúp giảm đáng kể nguy cơ overfitting, đặc biệt khi số lượng dữ liệu huấn luyện không quá lớn (2.202 items). Ngoài ra, số chiều nhỏ cũng giúp tăng tốc độ tính toán và giảm bộ nhớ lưu trữ.
- + **Thứ hai**, mô hình nhẹ và tốc độ xử lý nhanh. Mô hình all-MiniLM-L6-v2 có kích thước chỉ khoảng 80MB (so với hàng trăm MB của các mô hình BERT lớn). Điều này cho phép trích xuất đặc trưng văn bản một cách nhanh chóng, ngay cả trên máy tính có cấu hình khiêm tốn. Trong quá trình huấn luyện và triển khai, việc có một mô hình nhẹ là một lợi thế lớn.
- + **Thứ ba**, hoạt động tốt với văn bản ngắn như title sản phẩm. Mô hình all-MiniLM-L6-v2 được huấn luyện đặc biệt để xử lý các câu và đoạn văn bản ngắn (tối đa 256 token). Đây là điểm phù hợp hoàn hảo với dữ liệu title sản phẩm trong thương mại điện tử, vốn thường chỉ dài từ 5 đến 20 từ. Các mô hình ngôn ngữ lớn hơn (như BERT-large) có thể bị "lãng phí" khi xử lý văn bản quá ngắn.

– **Nhược điểm và hạn chế**

- + **Thứ nhất**, không nắm bắt được thông tin thị giác. Sentence-Transformers chỉ hoạt động trên dữ liệu văn bản, hoàn toàn không có khả năng xử lý ảnh. Điều này có nghĩa là các đặc tính thẩm mỹ quan trọng trong thời trang như màu sắc, họa tiết, kiểu dáng, độ tương phản... không thể được biểu diễn nếu chỉ dựa vào title sản phẩm. Ví dụ, hai chiếc áo có title giống nhau "Men's White Shirt" có thể rất khác nhau về chất liệu, form dáng, hoặc cổ áo, nhưng embedding văn bản sẽ không thể phân biệt được.
- + **Thứ hai**, có thể bỏ lỡ các đặc tính thẩm mỹ không được mô tả bằng lời. Nhiều đặc tính quan trọng trong thời trang thường không được phản ánh đầy đủ trong title sản phẩm. Ví dụ, một chiếc váy có thể có "cảm giác bay bổng" hay một đôi giày có "phong cách cổ điển" – những khái niệm trừu tượng này thường không xuất hiện trong title. Do đó, embedding văn bản chỉ là một nguồn thông tin bổ sung, không thể thay thế hoàn toàn cho đặc trưng thị giác.

- + **Thứ ba**, phụ thuộc vào chất lượng và độ chi tiết của title sản phẩm. Trong bộ dữ liệu Amazon, không phải title sản phẩm nào cũng được viết một cách nhất quán và đầy đủ. Một số sản phẩm có title rất ngắn và thiếu thông tin, dẫn đến embedding văn bản kém chất lượng. Đây là một hạn chế của dữ liệu thực tế mà hệ thống cần phải đối mặt.

2.2 Các phương pháp gợi ý trong hệ thống

Hệ thống gợi ý phối đồ thời trang được xây dựng dựa trên sự kết hợp giữa các phương pháp truyền thống và hiện đại, nhằm tận dụng tối đa các nguồn thông tin khác nhau: hành vi người dùng (thể hiện qua dữ liệu tương tác `also_bought`), đặc trưng thị giác (trích xuất từ ảnh sản phẩm) và đặc trưng văn bản (trích xuất từ title sản phẩm). Việc kết hợp đa phương thức này cho phép hệ thống đưa ra các gợi ý giày vừa phù hợp về mặt thống kê (dựa trên hành vi của những người dùng khác), vừa hài hòa về mặt thẩm mỹ (dựa trên đặc trưng ảnh và mô tả văn bản).

Hệ thống triển khai và so sánh bốn phương pháp gợi ý chính, mỗi phương pháp đại diện cho một mức độ kết hợp khác nhau giữa các nguồn thông tin:

Bảng 2. 5 so sánh bốn phương pháp gợi ý chính

Phương pháp	Mô tả ngắn	Mức độ kết hợp
LFM only	Chỉ sử dụng ELFMImproved (hành vi), không dùng đặc trưng ảnh hay văn bản	Cơ bản nhất
VGG Hybrid	Kết hợp ELFMImproved với VGG-DAE (đặc trưng ảnh VGG-19)	Trung bình
CLIP Hybrid	Kết hợp ELFMImproved với CLIP-DAE (đặc trưng ảnh CLIP)	Cao
CLIP+Text Hybrid	Kết hợp ELFMImproved với CLIP-DAE và Text-DAE (cả ảnh CLIP và văn bản)	Cao nhất


Mỗi phương pháp đều sử dụng ELFMImproved làm nhánh hành vi (dựa trên ID sản phẩm và dữ liệu triplets), kết hợp với một hoặc nhiều biến thể của Denoising Autoencoder (DAE) để khai thác đặc trưng thị giác và văn bản. Việc kết hợp giữa các

nhánh được thực hiện thông qua kỹ thuật Reciprocal Rank Fusion (RRF) – một phương pháp kết hợp thứ hạng không cần chuẩn hóa thang đo, cho phép tổng hợp thông tin từ nhiều nguồn khác nhau một cách hiệu quả và ổn định.

2.2.1. ELFMImproved

ELFMImproved là mô hình được cải tiến từ Local Factor Models (LFM) – một nhóm các mô hình nhân tử cục bộ thường được sử dụng trong các hệ thống gợi ý quy mô lớn. LFM truyền thống được thiết kế để học mối quan hệ từng cặp (pairwise) giữa các thực thể, ví dụ như giữa người dùng và sản phẩm trong bài toán dự đoán đánh giá, hoặc giữa hai sản phẩm trong bài toán gợi ý sản phẩm liên quan. Tuy nhiên, trong bài toán phối đồ thời trang, có ba loại thực thể cần xem xét đồng thời: áo (top), quần (bottom), và giày (shoe). Mối quan hệ giữa chúng không thể được biểu diễn đầy đủ bằng ba cặp độc lập, vì sự tương thích giữa áo và giày có thể phụ thuộc vào quần, và ngược lại.

ELFMImproved giải quyết vấn đề này bằng cách học đồng thời cả ba tương tác đôi một trong cùng một công thức. Thay vì học riêng lẻ từng cặp (top-bottom, bottom-shoe, top-shoe), ELFMImproved gộp cả ba tích vô hướng vào một biểu thức thống nhất, cho phép mô hình nắm bắt được sự phụ thuộc lẫn nhau giữa ba loại sản phẩm. Cách tiếp cận này phù hợp một cách tự nhiên với bản chất của bài toán phối đồ: một bộ (áo, quần, giày) là "đẹp" không chỉ vì áo hợp với quần, hay quần hợp với giày, mà còn vì cả ba tạo thành một tổng thể hài hòa.



Hình 2. 4 Mô hình ELFMImproved học tương tác giữa top, bottom và shoe

– **Công thức tính điểm:**

$$r(i, j, k) = (p_i \cdot p_j) + (p_j \cdot p_k) + (p_i \cdot p_k) + b_i + b_j + b_k \quad (2.2)$$

Trong đó:

- $P_i, P_j, P_k \in \mathbb{R}^d$: Vector embedding của top, bottom, shoe ($d=100$)
- b_i, b_j, b_k : Bias của từng sản phẩm
- $\cdot$: Tích vô hướng (dot product)

– **Các cải tiến so với LFM gốc:**

ELFMImproved không chỉ đơn thuần là mở rộng công thức từ hai tương tác lên ba tương tác, mà còn bao gồm nhiều cải tiến quan trọng khác nhằm nâng cao hiệu suất và độ ổn định của mô hình.

Bảng 2. 6 Cải tiến của ELFMImproved so với LFM gốc

Thành phần	LFM gốc	ELFMImproved
Công thức tính điểm	$(P_i \cdot P_j)$	$(P_i \cdot P_j) + (P_j \cdot P_k) + (P_i \cdot P_k)$
Bias	Không có	Có (b_i, b_j, b_k)
Dropout	Không	0.1
Negative sampling	Tỷ lệ 1:1	Tỷ lệ 4:1 (4 negative : 1 positive)
Optimizer	SGD	Adam
Hàm mất mát	MSE	Binary Cross Entropy (BCE)

– **Hàm mất mát:**

$$L_{BCE} = -\frac{1}{N} \sum_{(i,j,k) \in D} [y \log(\sigma(r)) + (1 - y) \log(1 - \sigma(r))] + \lambda \|\Theta\|^2 \quad (2.3)$$

Trong đó:

- y : Nhãn (1 cho triplet đúng, 0 cho negative sample)
- σ : Hàm sigmoid
- λ : Hệ số regularization
- Θ : Tập hợp tất cả tham số cần học

– **Ưu điểm của ELFMImproved**

ELFMImproved mang lại nhiều ưu điểm quan trọng cho hệ thống gợi ý phối đồ thời trang:

Bảng 2. 7 Ưu điểm của *ELFMImproved*

Ưu điểm	Giải thích
Học đồng thời mối quan hệ giữa cả ba loại sản phẩm	Không chỉ học từng cặp riêng lẻ mà học được sự tương tác lẫn nhau giữa áo, quần và giày trong cùng một biểu thức thống nhất
Không yêu cầu đặc trưng thị giác	Chỉ cần ID sản phẩm và dữ liệu triplets, có thể hoạt động ngay cả khi không có ảnh hoặc mô tả văn bản
Dễ mở rộng và giải thích	Công thức đơn giản, dễ hiểu, dễ mở rộng sang nhiều loại sản phẩm hơn (ví dụ thêm mũ, túi xách)
Có thể kết hợp với các phương pháp khác	Là nhánh hành vi trong các mô hình hybrid (VGG Hybrid, CLIP Hybrid, CLIP+Text Hybrid)

– **Hạn chế của *ELFMImproved*:**

Bên cạnh các ưu điểm, *ELFMImproved* cũng tồn tại một số hạn chế cần được quan tâm lưu ý:

Bảng 2. 8 Hạn chế của *ELFMImproved*

Hạn chế	Giải thích
Không sử dụng được đặc trưng thị giác và văn bản	Chỉ dựa vào ID sản phẩm, không thể phân biệt hai sản phẩm có hình dáng khác nhau nếu chúng có cùng ID (điều này không xảy ra, nhưng các sản phẩm khác nhau có thể có hành vi tương tự)
Hiệu suất phụ thuộc vào kích thước dữ liệu tương tác	Cần có đủ dữ liệu triplets để học embedding có ý nghĩa. Trong thí nghiệm với 43 triplets, mô hình hoàn toàn thất bại (accuracy ~0%)

Gặp vấn đề cold-start với sản phẩm mới	Sản phẩm mới chưa xuất hiện trong tập huấn luyện sẽ không có embedding, do đó không thể đưa ra gợi ý
--	--

Chính vì những hạn chế này, ELFMImproved thường được sử dụng **kết hợp** với các mô hình dựa trên đặc trưng thị giác và văn bản (DAE) thay vì sử dụng độc lập. Sự kết hợp này cho phép hệ thống tận dụng được ưu điểm của cả hai phương pháp: khả năng học mối quan hệ hành vi từ ELFMImproved và khả năng hiểu đặc trưng sản phẩm từ DAE. Kết quả thực nghiệm cho thấy mô hình **CLIP+Text Hybrid** (kết hợp ELFMImproved, CLIP-DAE và Text-DAE) đạt hiệu suất cao nhất với $\text{Accuracy}@10 = 79,0\%$, vượt trội so với LFM only, VGG Hybrid và CLIP Hybrid.

2.2.2. Denoising Autoencoder (DAE)

Denoising Autoencoder là một biến thể quan trọng và mạnh mẽ của Autoencoder, được huấn luyện để tái tạo đầu ra từ đầu vào bị nhiễu, giúp mô hình học được các đặc trưng bền vững (robust features) và có khả năng khôi phục thông tin bị thiếu một cách thông minh. Khác với Autoencoder truyền thống chỉ đơn thuần học cách sao chép đầu vào sang đầu ra (dễ dẫn đến tình trạng hàm đồng nhất – identity function), Denoising Autoencoder buộc mô hình phải hiểu được cấu trúc tiềm ẩn của dữ liệu. Bằng cách yêu cầu mô hình tái tạo lại dữ liệu gốc từ một phiên bản đã bị làm hỏng hoặc thiếu thông tin, DAE không thể học một cách đơn giản là "sao chép và dán" mà phải thực sự nắm bắt được các đặc trưng cốt lõi, bản chất nhất của dữ liệu.

Trong bối cảnh của bài toán gợi ý phối đồ thời trang, DAE được áp dụng một cách rất sáng tạo để giải quyết bài toán "Complete the Look". Thay vì sử dụng nhiễu ngẫu nhiên như các ứng dụng truyền thống (ví dụ: thêm nhiễu Gaussian vào ảnh hoặc che giấu ngẫu nhiên các pixel), hệ thống tạo ra một dạng nhiễu đặc biệt có chủ đích: che giấu hoàn toàn thông tin của giày (shoe). Cách tiếp cận này hoàn toàn phù hợp với bản chất của bài toán: từ thông tin của áo (top) và quần (bottom), mô hình cần phải "đoán" hoặc "tưởng tượng" ra đặc trưng của giày phù hợp nhất.

– **Nguyên lý hoạt động:**


- + Input bị nhiễu: $\tilde{\mathbf{x}} = [\text{top_feat}, \text{bottom_feat}, 0]$
- + Output tái tạo: $\hat{\mathbf{y}} = [\text{top_feat}, \text{bottom_feat}, \text{shoe_feat}]$

+ Mục tiêu: Tái tạo lại shoe feature chính xác

Bảng 2. 9 Nguyên lý hoạt động của Denoising Autoencoder

Thành phần	Mô tả	Ký hiệu
Input bị nhiễu (Corrupted Input)	Vector ghép của đặc trưng áo, đặc trưng quần, và vector zero (thiếu thông tin giày). Đây là "phiên bản bị hỏng" mà mô hình nhận được.	$\tilde{x} = [\text{top_feat}, \text{bottom_feat}, 0]$
Output tái tạo (Reconstructed Output)	Vector đầy đủ bao gồm đặc trưng áo, đặc trưng quần, và đặc trưng giày do mô hình dự đoán. Đây là kết quả mà mô hình xuất ra.	$\hat{y} = [\text{top_feat}, \text{bottom_feat}, \text{shoe_feat}]$
Target (Mục tiêu)	Vector đầy đủ thực tế, bao gồm đặc trưng áo, đặc trưng quần, và đặc trưng giày thật (ground truth). Mô hình sẽ học để $\hat{y}$ càng gần x càng tốt.	$x = [\text{top_feat}, \text{bottom_feat}, \text{shoe_feat_thật}]$
Mục tiêu của DAE	Tái tạo lại shoe feature một cách chính xác nhất có thể, dựa chỉ vào thông tin của áo và quần.	Minimize $\ \hat{y} - x\ ^2$

Điểm đặc biệt ở đây là DAE không được nhìn thấy đặc trưng giày trong đầu vào, nhưng vẫn phải tái tạo lại nó trong đầu ra. Điều này buộc mô hình phải học được mối quan hệ ngầm giữa áo, quần và giày: nó phải biết rằng "với áo trắng và quần jeans xanh thì giày thể thao trắng sẽ phù hợp", hay "với áo sơ mi và quần tây đen thì giày da nâu sẽ hợp lý".



Hình 2. 5 Kiến trúc Denoising Autoencoder cho bài toán gợi ý giày

– Công thức của Denoising Autoencoder:

$$\mathbf{h} = \mathbf{f}_{enc}(\tilde{\mathbf{x}}) = \sigma(\mathbf{W}_{enc}\tilde{\mathbf{x}} + \mathbf{b}_{enc}) \quad (2.4)$$

$$\hat{\mathbf{y}} = \mathbf{f}_{dec}(\mathbf{h}) = \sigma(\mathbf{W}_{dec}\mathbf{h} + \mathbf{b}_{dec}) \quad (2.5)$$

$$\mathcal{L}_{DAE} = \|\hat{\mathbf{y}} - \mathbf{x}\|^2 = \sum_{i=1}^n (\hat{y}_i - x_i)^2 \quad (2.6)$$

Trong đó:

- $\tilde{\mathbf{x}}$: Input bị nhiễu (thiếu shoe feature)
- $\mathbf{x}$: Target đầy đủ (có shoe feature)
- $\mathbf{h}$: Latent representation (không gian tiềm ẩn)
- $\mathcal{L}_{DAE}$: Hàm mất mát Mean Squared Error (MSE)

Tại sao lại dùng MSE loss? Bởi vì bài toán tái tạo đặc trưng giày là một bài toán hồi quy (regression): mô hình cần dự đoán một vector số thực liên tục, không phải một nhãn rời rạc. MSE là lựa chọn phổ biến nhất cho các bài toán hồi quy vì nó có đạo hàm đơn giản và dễ tối ưu bằng gradient descent.

– Mối quan hệ giữa DAE và quá trình dự đoán giày:

Sau khi huấn luyện xong DAE, để dự đoán giày cho một cặp (top, bottom) mới, hệ thống thực hiện:

- + Tạo $\tilde{\mathbf{x}} = [\text{feat_top}, \text{feat_bottom}, 0]$
- + Đưa $\tilde{\mathbf{x}}$ qua encoder để có $\mathbf{h}$, sau đó qua decoder để có $\hat{\mathbf{y}}$
- + Trích xuất phần shoe_feat từ $\hat{\mathbf{y}}$
- + Tính cosine similarity giữa shoe_feat này với tất cả giày trong database
- + Trả về top-K giày có similarity cao nhất

– **Ba biến thể DAE trong đề tài:**

Trong đề tài này, ba biến thể DAE khác nhau được triển khai, mỗi biến thể sử dụng một loại đặc trưng đầu vào khác nhau và có kiến trúc mạng tương ứng

Bảng 2. 10 Ba biến thể Denoising Autoencoder

Biến thể	Loại đặc trưng	Input dimension	Kiến trúc	Hàm mất mát
VGG-DAE	VGG-19 (4096 chiều)	12,288 (4096×3)	Conv1D (3 layers)	MSE
CLIP-DAE	CLIP (512 chiều)	1,536 (512×3)	MLP (Linear layers)	MSE
Text-DAE	Text (384 chiều)	1,152 (384×3)	MLP (Linear layers)	MSE

Bảng 2. 11 sự khác biệt về kiến trúc ba biến thể Denoising Autoencoder

Biến thể	Lý do chọn kiến trúc
VGG-DAE	Sử dụng Conv1D vì input có số chiều rất lớn (12.288). Conv1D có thể phát hiện các mô hình cục bộ (local patterns) trong vector đặc trưng, giúp giảm số lượng tham số so với MLP thuần túy.
CLIP-DAE	Sử dụng MLP (Multi-Layer Perceptron) với các tầng Linear vì input chỉ có 1.536 chiều, hoàn toàn có thể xử lý bằng MLP mà không lo overfitting quá mức.
Text-DAE	Cũng sử dụng MLP tương tự CLIP-DAE, với số chiều input là 1.152. Kiến trúc đối xứng (số chiều giảm dần rồi tăng dần) giúp học được biểu diễn nén tốt.

– **Kiến trúc CLIP-DAE chi tiết:**

Trong ba biến thể, CLIP-DAE là quan trọng nhất vì nó đóng góp trực tiếp vào mô hình hybrid tốt nhất (CLIP+Text Hybrid). Kiến trúc chi tiết của CLIP-DAE được thiết kế như sau:

Encoder (bộ mã hóa):

- + Tầng Linear thứ nhất: $1.536 \rightarrow 1.024$, kèm ReLU và Dropout(0.2)
- + Tầng Linear thứ hai: $1.024 \rightarrow 512$, kèm ReLU và Dropout(0.2)
- + Tầng Linear thứ ba: $512 \rightarrow 256$, kèm ReLU (không dropout ở tầng cuối của encoder)

Decoder (bộ giải mã):

- + Tầng Linear thứ nhất: $256 \rightarrow 512$, kèm ReLU và Dropout(0.2)
- + Tầng Linear thứ hai: $512 \rightarrow 1.024$, kèm ReLU và Dropout(0.2)
- + Tầng Linear thứ ba: $1.024 \rightarrow 1.536$, kèm ReLU

Bảng 2. 12 Giải thích các lựa chọn thiết kế Denoising Autoencoder

Thiết kế	Lý do
Giảm dần số chiều ở encoder ($1536 \rightarrow 1024 \rightarrow 512 \rightarrow 256$)	Trích xuất các đặc trưng quan trọng nhất, loại bỏ thông tin dư thừa và nhiễu
Tăng dần số chiều ở decoder ($256 \rightarrow 512 \rightarrow 1024 \rightarrow 1536$)	Tái tạo lại dữ liệu từ biểu diễn nén, cấu trúc đối xứng với encoder
Dropout(0.2) ở hầu hết các tầng	Chống overfitting, đặc biệt quan trọng khi số lượng dữ liệu huấn luyện không quá lớn
ReLU làm hàm kích hoạt	Giúp mô hình học được các mối quan hệ phi tuyến, tránh hiện tượng vanishing gradient
Latent space 256 chiều	Cân bằng giữa khả năng biểu diễn và khả năng tổng quát hóa

– **Ưu điểm:**

- + Học được phân phối đặc trưng thị giác/văn bản: DAE không chỉ học các cặp cụ thể mà học được toàn bộ phân phối xác suất của các đặc trưng trong không gian tiềm ẩn, giúp khái quát hóa tốt cho các sản phẩm chưa thấy trong quá khứ
- + Có thể khôi phục thông tin bị thiếu (shoe feature): Đây chính là mục đích chính của DAE trong bài toán này: từ top và bottom, mô hình có thể "đoán" được đặc trưng của giày phù hợp mà không cần nhìn thấy nó

- + Xử lý được nhiễu trong dữ liệu: Trong thực tế, ảnh sản phẩm có thể bị mờ, thiếu sáng, có nền phức tạp hoặc bị chụp từ góc không tốt. DAE được thiết kế để kháng nhiễu nên vẫn hoạt động tốt trong các điều kiện này
- **Hạn chế:**
 - + Cần đặc trưng đầu vào chất lượng cao: DAE chỉ học được tốt nếu đặc trưng đầu vào thực sự phản ánh đúng bản chất của sản phẩm. Nếu đặc trưng kém chất lượng (như VGG-19 với 4096 chiều quá thừa và nhiễu), DAE sẽ học sai
 - + Với VGG (4096 chiều), hiệu suất reconstruct kém (cosine similarity ~ 0.326): Cosine similarity chỉ đạt khoảng 0,326, dẫn đến chất lượng gợi ý rất thấp (chỉ 5-7% Accuracy@10). Nguyên nhân là "curse of dimensionality": khi số chiều quá lớn so với số lượng mẫu huấn luyện, các điểm dữ liệu trở nên thưa thớt và khoảng cách giữa chúng mất đi ý nghĩa
 - + Không học được mối quan hệ tương minh giữa các loại sản phẩm: DAE học ngầm (implicitly) qua quá trình reconstruct, không có công thức tương minh như ELFMImproved. Do đó, rất khó để giải thích tại sao một bộ đồ lại được coi là phù hợp dưới góc nhìn của DAE

2.2.3. Reciprocal Rank Fusion (RRF)

Reciprocal Rank Fusion (RRF) là một kỹ thuật kết hợp ranking (rank aggregation) từ nhiều nguồn khác nhau mà không cần chuẩn hóa thang đo. Đây là một phương pháp đơn giản nhưng hiệu quả, được sử dụng rộng rãi trong các hệ thống tìm kiếm và gợi ý khi cần tổng hợp kết quả từ nhiều bộ xếp hạng độc lập. Thay vì nhân thứ hạng (rank multiplication) như phương pháp hybrid truyền thống – vốn có nhược điểm là dễ bị ảnh hưởng bởi một giá trị thứ hạng bất thường (outlier) – RRF tính điểm tổng hợp dựa trên nghịch đảo của thứ hạng (reciprocal of ranks). Cách tiếp cận này đảm bảo rằng mỗi nguồn thông tin đều có đóng góp vào kết quả cuối cùng, đồng thời giảm thiểu tác động của các thứ hạng quá cao hoặc quá thấp.

Bảng 2. 13 Lý do cần RRF thay vì các phương pháp kết hợp khác

Phương pháp kết hợp	Cách hoạt động	Nhược điểm
Rank Multiplication	Nhân các thứ hạng với nhau: $W = \text{rank}_1 \times \text{rank}_2 \times \dots$	Nếu một nguồn đánh giá sản phẩm ở hạng rất thấp (ví dụ rank=100), tích số sẽ bị "chết" ngay lập tức, bỏ qua ý kiến của các nguồn khác
Trung bình cộng (Mean)	Tính trung bình các thứ hạng	Cần chuẩn hóa thang đo vì các nguồn có thể có thang đo khác nhau; dễ bị ảnh hưởng bởi outlier
Trung vị (Median)	Lấy giá trị ở giữa của các thứ hạng	Ít được sử dụng trong thực tế, mất thông tin về phân phối
RRF	Tính tổng nghịch đảo của $(k + \text{rank})$	Không cần chuẩn hóa, giảm ảnh hưởng của outlier, dễ mở rộng

– Công thức RRF:

$$\text{RRFscore}(s) = \sum_{r \in R} \frac{1}{k + \text{rank}_r(s)} \quad (2.7)$$

Trong đó:

- **s**: Ứng viên giày (shoe candidate)
- **R**: Tập hợp các phương pháp gợi ý thành phần (ví dụ: ELFMImproved, CLIP-DAE, Text-DAE)
- **rank_r(s)**: Thứ hạng của giày ss trong kết quả của phương pháp *r* (bắt đầu từ 1)
- **k**: Hằng số (thường chọn $k=60$)
- **Tại sao lại chọn k = 60?**
 - + *k* quá nhỏ (ví dụ 0 hoặc 1): Phương pháp xếp hạng 1 sẽ có trọng số quá lớn ($1/1 = 1$), lấn át các phương pháp khác

- + k quá lớn (ví dụ 1000): Sự khác biệt giữa các thứ hạng bị san phẳng, mất tính phân biệt
- + $k = 60$ (được chọn): Cân bằng giữa việc ưu tiên các thứ hạng cao (đóng góp ~ 0.0164 cho hạng 1) và vẫn giữ được sự khác biệt giữa các thứ hạng

Giả sử có 3 phương pháp gợi ý: ELFMImproved, CLIP-DAE, Text-DAE. Xét một đôi giày S1 có thứ hạng từ mỗi phương pháp như sau:


Bảng 2. 14 Ví dụ cụ thể về cách tính RRFscore

Phương pháp	rank_r(S1)	Đóng góp = $1/(60 + \text{rank})$	Giá trị
ELFMImproved	1	$1/(60+1) = 1/61$	$\approx 0,01639$
CLIP-DAE	3	$1/(60+3) = 1/63$	$\approx 0,01587$
Text-DAE	2	$1/(60+2) = 1/62$	$\approx 0,01613$

$$\text{RRFscore}(S1) = 0,01639 + 0,01587 + 0,01613 = 0,04839$$

Tương tự, tính cho các giày khác, sau đó xếp hạng theo RRFscore giảm dần (điểm càng cao càng tốt).

– Quy trình kết hợp RRF trong hệ thống



Hình 2. 6 Quy trình Reciprocal Rank Fusion cho hệ thống gợi ý phối đồ

Quy trình kết hợp RRF trong hệ thống gợi ý phối đồ thời trang được thực hiện qua các bước sau:

Bước 1 – Chạy từng phương pháp thành phần:

- + Với mỗi cặp (top, bottom) đầu vào, hệ thống chạy ELFMImproved để có danh sách giày xếp hạng theo hành vi người dùng.
- + Đồng thời, chạy CLIP-DAE để có danh sách giày xếp hạng theo đặc trưng thị giác.
- + Đồng thời, chạy Text-DAE để có danh sách giày xếp hạng theo đặc trưng văn bản.

Bước 2 – Chuẩn bị thứ hạng:

- + Mỗi phương pháp trả về một danh sách các giày candidate, kèm theo thứ hạng (1, 2, 3, ..., N) dựa trên độ phù hợp.
- + Thứ hạng 1 là giày được phương pháp đó đánh giá là phù hợp nhất.
- + Bước 3 – Tính RRFscore cho mỗi giày:
- + Với mỗi giày s xuất hiện trong ít nhất một danh sách, tính RRFscore(s) theo công thức (2.7).
- + Nếu giày s không xuất hiện trong danh sách của một phương pháp, thường được gán $\text{rank} = \infty$ hoặc $\text{rank} = (\text{số lượng giày} + 1)$, khi đó đóng góp ≈ 0 .
- + Bước 4 – Xếp hạng tổng hợp:
- + Sắp xếp các giày theo RRFscore giảm dần (giá trị càng cao càng phù hợp).
- + Trả về top-K giày có RRFscore cao nhất làm kết quả gợi ý cuối cùng.

– **So sánh RRF với Rank Multiplication (phương pháp cũ)**

Bảng 2. 15 So sánh RRF với Rank Multiplication

Tiêu chí	Rank Multiplication	RRF
Công thức	$W = \text{rank}_1 \times \text{rank}_2 \times \text{rank}_3$	$\text{RRFscore} = \sum 1/(\text{k} + \text{rank_r})$
Cách xử lý outlier	Rất kém: một rank cao (ví dụ 100) sẽ làm tích số cực lớn, loại giày đó ra khỏi top đầu ngay lập tức	Tốt: đóng góp của $\text{rank}=100$ chỉ là $1/160 \approx 0,00625$, vẫn còn cơ hội nếu các rank khác tốt
Kết hợp nhiều nguồn	Tích số càng nhiều số càng dễ bị tràn hoặc quá nhỏ	Tổng đơn giản, dễ mở rộng thêm nhiều nguồn

Yêu cầu chuẩn hóa	Không cần (vì thang đo giống nhau: đều là thứ hạng)	Không cần (vì dùng chung tham số k)
Khả năng phân biệt	Tốt nhưng dễ bị "chết" bởi một nguồn kém	Tốt và ổn định hơn
Ứng dụng trong đề tài	Không sử dụng	Được sử dụng cho VGG Hybrid, CLIP Hybrid, CLIP+Text Hybrid

– Ưu điểm của RRF

- + Không cần chuẩn hóa thang đo giữa các phương pháp: ELFMImproved trả ra score (xác suất), CLIP-DAE trả ra cosine similarity (0-1), Text-DAE cũng trả ra cosine similarity. Các thang đo này khác nhau và không thể so sánh trực tiếp. RRF làm việc với thứ hạng – một thang đo thống nhất cho mọi phương pháp – nên không cần chuẩn hóa phức tạp
- + Giảm ảnh hưởng của các outlier ranking: Nếu một phương pháp "có vấn đề" xếp một giày tốt ở hạng rất thấp (ví dụ rank=100) do lỗi, RRF vẫn cho giày đó cơ hội gỡ điểm từ các phương pháp khác. Trong khi rank multiplication sẽ "giết chết" giày đó ngay lập tức
- + Dễ triển khai và kết hợp nhiều nguồn: Công thức đơn giản, chỉ cần biết thứ hạng của từng giày từ mỗi phương pháp. Dễ dàng thêm phương pháp thứ tư, thứ năm mà không cần thay đổi cấu trúc
- + Ổn định và hiệu quả: Đã được chứng minh qua nhiều nghiên cứu trong lĩnh vực tìm kiếm và gợi ý, RRF cho kết quả ổn định và thường tốt hơn các phương pháp kết hợp đơn giản khác

– Ứng dụng của RRF trong bốn phương pháp của đề tài

Trong mô hình CLIP+Text Hybrid – mô hình tốt nhất của đề tài – RRF kết hợp cả ba nguồn: hành vi (ELFMImproved), thị giác (CLIP-DAE), và văn bản (Text-DAE). Nhờ RRF, cả ba "chuyên gia" đều có tiếng nói trong quyết định cuối cùng, dẫn đến kết quả $\text{Accuracy}@10 = 79,0\%$ – vượt trội so với chỉ dùng hai nguồn (CLIP Hybrid đạt 45,5%).

Bảng 2. 16 Ứng dụng của RRF trong bốn phương pháp của đề tài

Phương pháp	Các nguồn kết hợp	Số nguồn
LFM only	Không dùng RRF (chỉ một nguồn)	1
VGG Hybrid	ELFMImproved + VGG-DAE	2
CLIP Hybrid	ELFMImproved + CLIP-DAE	2
CLIP+Text Hybrid	ELFMImproved + CLIP-DAE + Text-DAE	3

2.2.4. Bốn phương pháp gợi ý trong đề tài


Bảng 2. 17 Bốn phương pháp gợi ý được triển khai

Phương pháp	Các thành phần	Kỹ thuật kết hợp
LFM only	ELFMImproved	Không (chỉ dùng ELFMImproved)
VGG Hybrid	ELFMImproved + VGG-DAE	RRF
CLIP Hybrid	ELFMImproved + CLIP-DAE	RRF
CLIP+Text Hybrid	ELFMImproved + CLIP-DAE + Text-DAE	RRF

– **Mô tả từng phương pháp:**

- + LFM only: Chỉ sử dụng ELFMImproved dựa trên dữ liệu tương tác (triplets), không dùng đặc trưng thị giác hay văn bản.
- + VGG Hybrid: Kết hợp ELFMImproved với VGG-DAE (đặc trưng VGG-19 4096 chiều) thông qua RRF.
- + CLIP Hybrid: Kết hợp ELFMImproved với CLIP-DAE (đặc trưng CLIP 512 chiều) thông qua RRF.

- + CLIP+Text Hybrid: Kết hợp ELFMImproved với cả CLIP-DAE và Text-DAE (đặc trưng văn bản 384 chiều) thông qua RRF. Đây là mô hình cho kết quả tốt nhất.



Hình 2. 7 Kiến trúc tổng thể hệ thống gợi ý phối đồ đa phương thức

2.3 Các chỉ số đánh giá mô hình

Để đánh giá hiệu suất của các mô hình gợi ý phối đồ thời trang, ba chỉ số phổ biến được sử dụng: Precision@K, Recall@K và Accuracy@K (còn gọi là Hit Rate@K). Các chỉ số này được tính trên tập test gồm 200 test cases, mỗi test case có 1 ground truth shoe và 299 candidate shoes ngẫu nhiên.

2.3.1. Precision@K

Precision@K đo lường tỷ lệ sản phẩm được gợi ý phù hợp trong danh sách top-K.

– **Công thức:**

$$Precision@K = \frac{|relevant\ items \cap top-K\ recommended\ items|}{K} \quad (2.8)$$

– **Ví dụ:** Nếu top-10 giày gợi ý có 3 đôi phù hợp với ground truth $\rightarrow$ Precision@10 = 3/10 = 0,3

– **Ý nghĩa:** Precision@K càng cao chứng tỏ hệ thống gợi ý càng chính xác, ít sản phẩm không phù hợp xuất hiện trong danh sách gợi ý.

2.3.2. Recall@K

Recall@K đo lường tỷ lệ sản phẩm phù hợp được bao phủ trong danh sách top-K. Chỉ số này cho biết trong tổng số sản phẩm phù hợp, hệ thống đã gợi ý được bao nhiêu phần trăm.

– **Công thức:**

$$Recall@K = \frac{|relevant\ items \cap top-K\ recommended\ items|}{|relevant\ items|} \quad (2.9)$$

- **Ví dụ:** Nếu mỗi test case có 1 ground truth shoe duy nhất, và ground truth đó xuất hiện trong top-10 $\rightarrow Recall@10 = 1/1 = 1,0$ (cho test case đó). Trung bình trên tất cả test cases sẽ cho kết quả Recall@10.
- **Ý nghĩa:** Recall@K càng cao chứng tỏ hệ thống có khả năng bao phủ tốt các sản phẩm phù hợp.
- **Đặc điểm trong bài toán này:** Do mỗi test case chỉ có 1 ground truth shoe duy nhất (một cặp top-bottom chỉ phù hợp với một đôi giày cụ thể trong tập dữ liệu), Recall@K trong trường hợp này bằng với tỷ lệ test cases mà ground truth xuất hiện trong top-K.

2.3.3. Accuracy@K (Hit Rate@K)

Accuracy@K (hay Hit Rate@K) đo lường tỷ lệ test cases mà ground truth shoe nằm trong danh sách top-K được gợi ý. Đây là chỉ số chính để đánh giá hiệu quả tổng thể của hệ thống.

– **Công thức:**

$$Accuracy@K = \left(\frac{1}{N}\right) \sum_{i=1}^N \mathbf{1}(ground_{truth_i} \in top - K_i) \quad (2.10)$$

Trong đó:

- **N:** Tổng số test cases ($N = 200$)
- **$\mathbf{1}(\cdot)$:** Hàm chỉ báo (bằng 1 nếu điều kiện đúng, bằng 0 nếu sai)
- **ground_truth_i:** Sản phẩm giày đúng của test case thứ i
- **top-K_i:** Danh sách K sản phẩm giày được gợi ý cho test case thứ i
- **Ví dụ:** Nếu có 200 test cases, trong đó 158 test cases có ground truth xuất hiện trong top-10 $\rightarrow Accuracy@10 = 158/200 = 0,79$ (79%)

- **Ý nghĩa:** Accuracy@K cho biết khả năng hệ thống đưa ra câu trả lời đúng trong K gợi ý đầu tiên. Giá trị này càng cao, trải nghiệm người dùng càng tốt vì người dùng không cần xem quá nhiều gợi ý để tìm được sản phẩm phù hợp.

Bảng 2. 18 Tổng hợp các chỉ số đánh giá

Chỉ số	Công thức	Ý nghĩa	Giá trị trong đề tài (CLIP+Text Hybrid)
Precision@K	số đúng trong top-K / K	Độ chính xác của gợi ý	-
Recall@K	số đúng trong top-K / tổng số đúng	Độ bao phủ	Bằng Accuracy@K
Accuracy@K	số test case có ground truth trong top-K / N	Tỷ lệ gợi ý đúng	79,0% (@10), 84,5% (@15), 85,5% (@20)

2.4 Tổng kết chương 2

Trong chương này, đã trình bày các thuật toán và mô hình trong hệ thống gợi ý phối đồ thời trang, từ các phương pháp trích xuất đặc trưng thị giác và văn bản đến các phương pháp gợi ý chính và các chỉ số đánh giá.

- Về trích xuất đặc trưng: VGG-19 (4096 chiều), CLIP (512 chiều) và Sentence-Transformers (384 chiều). CLIP vượt trội nhờ ngữ nghĩa cao và số chiều phù hợp.
- Về phương pháp gợi ý: Bốn phương pháp gồm LFM only, VGG Hybrid, CLIP Hybrid và CLIP+Text Hybrid, sử dụng ELFMImproved, Denoising Autoencoder và kỹ thuật kết hợp RRF.
- Về chỉ số đánh giá: Precision@K, Recall@K và Accuracy@K (Hit Rate@K).
- Việc kết hợp đa phương thức giúp xây dựng hệ thống gợi ý phối đồ hiệu quả. Chương tiếp theo sẽ triển khai cụ thể các mô hình này trên bộ dữ liệu Amazon Clothing, Shoes & Jewelry.

CHƯƠNG 3: XÂY DỰNG MÔ HÌNH VÀ HỆ THỐNG GỢI Ý THỜI TRANG

Chương này trình bày quy trình xây dựng hệ thống gợi ý phối đồ thời trang, bao gồm: mô tả bộ dữ liệu, các bước tiền xử lý và tăng cường dữ liệu, huấn luyện các mô hình (ELFMImproved, Denoising Autoencoder, các mô hình Hybrid), và triển khai hệ thống web demo StyleAI.

3.1 Giới thiệu bài toán

Bài toán đặt ra là xây dựng một hệ thống gợi ý thời trang có khả năng đề xuất giày (shoe) phù hợp dựa trên cặp sản phẩm áo (top) và quần (bottom) mà người dùng đã chọn. Đây là bài toán "Complete the Look" với hai yêu cầu chính:

- **Tương thích thị giác:** Giày được đề xuất phải phù hợp về mặt thẩm mỹ với áo và quần
- **Tương thích hành vi:** Giày được đề xuất phải phù hợp với xu hướng phối đồ từ dữ liệu tương tác

Hệ thống triển khai bốn phương pháp và so sánh kết quả: LFM only, VGG Hybrid, CLIP Hybrid, và CLIP+Text Hybrid.

3.2 Dữ liệu


3.2.1. Nguồn dữ liệu

Hệ thống sử dụng bộ dữ liệu Amazon Clothing, Shoes & Jewelry – một trong những bộ dữ liệu lớn và phổ biến nhất trong lĩnh vực gợi ý thời trang.

Bảng 3. 1 Các tệp dữ liệu đầu vào

Tệp tin	Số lượng	Mô tả
triplets.csv	2.669 triplets	Bộ ba (top, bottom, shoe) gốc
meta_Clothing_Shoes_and_Jewelry.json	~1.5 triệu sản phẩm	Thông tin title, categories, also_bought

image_features.npy	2.202 items	Đặc trưng VGG-19 (4096 chiều)
clip_embeddings.npy	2.202 items	Đặc trưng CLIP ViT-B-32 (512 chiều)



Hình 3. 1 Cấu trúc bộ dữ liệu Amazon Fashion

3.2.2. Phân loại sản phẩm

Do dữ liệu không có nhãn phân loại trực tiếp, hệ thống thực hiện phân loại bằng phương pháp rule-based dựa trên trường categories và title.

Bảng 3. 2 Kết quả phân loại sản phẩm

Loại sản phẩm	Số lượng (toàn bộ)	Số lượng (có features)
Tops	324.900	~800
Bottoms	82.508	~400
Shoes	1.095.976	~1.000
Other	0 (đã lọc)	0

3.2.3. Quy trình xử lý dữ liệu

- **Chi tiết các bước:**
 - + **Bước 1 – Đọc dữ liệu:** Đọc file meta_Clothing_Shoes_and_Jewelry.json (1.503.384 sản phẩm).
 - + **Bước 2 – Phân loại sản phẩm:** Xác định loại (top/bottom/shoe) bằng từ khóa trong categories và title.
 - + **Bước 3 – Tạo triplets từ dữ liệu gốc:** Đọc 2.669 triplets từ triplets.csv.
 - + **Bước 4 – Tăng cường dữ liệu:** Sử dụng quan hệ also_bought từ metadata để sinh thêm triplets.
 - + **Bước 5 – Lọc triplets hợp lệ:** Chỉ giữ triplets có cả 3 sản phẩm đều có features (VGG-19 và CLIP).
 - + **Bước 6 – Train/Test split:** Chia ngẫu nhiên với tỷ lệ 90/10 (random seed = 42).

Bảng 3. 3 Kết quả xử lý dữ liệu

Giai đoạn	Số lượng
Triplets gốc	2.669
Sau khi tăng cường (also_bought)	324.418
Số items có features	2.202
Triplets hợp lệ (có đủ features)	2.210
Train split (90%)	1.989
Test split (10%)	221

3.2.4. Chuẩn bị dữ liệu cho từng mô hình

- **Đối với ELFMImproved:**
 - + Xây dựng ánh xạ item $\rightarrow$ chỉ số (0 đến 2.201)
 - + Tạo positive samples: 2.210 triplets, nhãn = 1
 - + Tạo negative samples: thay shoe bằng shoe ngẫu nhiên, tỷ lệ 4:1 (8.840 samples), nhãn = 0

– **Đối với các DAE:**

Bảng 3. 4 Cấu trúc dữ liệu cho từng biến thể DAE

Biến thể	Input (masked)	Target	Số chiều input
VGG-DAE	[f_top, f_bottom, zeros]	[f_top, f_bottom, f_shoe]	12.288
CLIP-DAE	[f_top, f_bottom, zeros]	[f_top, f_bottom, f_shoe]	1.536
Text-DAE	[f_top, f_bottom, zeros]	[f_top, f_bottom, f_shoe]	1.152

3.3 Huấn luyện mô hình ELFMImproved

3.3.1. Thiết lập tham số

Bảng 3. 5 Tham số huấn luyện ELFMImproved

Tham số	Giá trị	Giải thích
latent_dim	100	Số chiều embedding
learning_rate	0.001	Tốc độ học
batch_size	128	Số mẫu mỗi batch
dropout	0.1	Tỷ lệ dropout
weight_decay	0.001	Hệ số L2 regularization
negative_ratio	4:1	Tỷ lệ negative:positive
optimizer	Adam	Thuật toán tối ưu
epochs	40	Số vòng lặp huấn luyện

3.3.2. Quá trình huấn luyện

- **Quá trình huấn luyện ELFMImproved được thực hiện theo các bước sau:**
 - + **Bước 1 – Khởi tạo tham số:** Các embedding vector p_i , p_j , p_k có kích thước 100 chiều được khởi tạo ngẫu nhiên. Các bias b_i , b_j , b_k được khởi tạo bằng 0. Bộ tối ưu Adam được cấu hình với learning rate = 0,001.

- + **Bước 2 – Lấy batch dữ liệu:** Mỗi batch gồm 128 mẫu, bao gồm cả positive samples (nhãn = 1) và negative samples (nhãn = 0) theo tỷ lệ 1:4. Negative samples được tạo bằng cách thay thế shoe trong triple đúng bằng một shoe ngẫu nhiên khác.
- + **Bước 3 – Tính điểm tương thích:** Với mỗi mẫu trong batch, hệ thống tính điểm theo công thức (3.2) đã trình bày tại Chương 2. Điểm số này được đưa qua hàm sigmoid để chuyển thành xác suất dự đoán.
- + **Bước 4 – Tính hàm mất mát:** Hàm mất mát Binary Cross Entropy (BCE) được tính theo công thức (3.3) Chương 2, có bổ sung thành phần L2 regularization với hệ số 0,001 để chống overfitting.
- + **Bước 5 – Cập nhật trọng số:** Bộ tối ưu Adam cập nhật các embedding vector và bias dựa trên gradient của hàm mất mát. Lớp Dropout với tỷ lệ 0,1 được áp dụng sau tầng embedding để tránh overfitting.
- + **Bước 6 – Lặp lại:** Các bước 2-5 được lặp lại qua 40 epochs trên toàn bộ tập huấn luyện.

3.3.3. Kết quả huấn luyện

Bảng 3. 6 Kết quả huấn luyện ELFMImproved

Epoch	Train Loss	Validation Accuracy
1	0,6852	52,3%
5	0,5421	68,7%
10	0,4123	78,2%
15	0,3218	83,5%
20	0,2654	85,9%
25	0,2210	87,0%
30	0,1892	87,2%
35	0,1651	87,1%
40	0,1478	87,0%

Nhận xét:

- Loss giảm dần từ 0,6852 xuống 0,1478 sau 40 epochs, cho thấy mô hình học được các mối quan hệ.
- Validation accuracy tăng từ 52,3% lên 87,2% sau 30 epochs.
- Mô hình đạt accuracy cao nhất tại epoch 30 (87,2%), sau đó ổn định, không có dấu hiệu overfitting.
- Kết quả này chứng tỏ ELFMIImproved hoạt động hiệu quả trên tập dữ liệu với 2.202 items và 1.989 triplets huấn luyện.

3.4 Huấn luyện các mô hình Denoising Autoencoder

3.4.1. Thiết lập tham số chung

Bảng 3. 7 Tham số huấn luyện chung cho các DAE

Tham số	Giá trị
learning_rate	0,001
batch_size	32
epochs	100
optimizer	Adam
loss_function	MSELoss

3.4.2. Quá trình huấn luyện

- **Quá trình huấn luyện Denoising Autoencoder được thực hiện theo các bước sau:**
 - + **Bước 1 – Tạo đầu vào bị nhiễu:** Với mỗi triple (top, bottom, shoe) trong tập huấn luyện, hệ thống tạo vector đầu vào $\tilde{x}$ bằng cách ghép đặc trưng của top, đặc trưng của bottom, và vector zero (thiếu shoe). Vector target x là vector đầy đủ gồm đặc trưng top, bottom và shoe.
 - + **Bước 2 – Mã hóa (Encoder):** Vector đầu vào $\tilde{x}$ được đưa qua encoder. Đối với CLIP-DAE và Text-DAE, encoder là các tầng Linear kết hợp với ReLU và Dropout(0,2). Đối với VGG-DAE, encoder sử dụng Conv1D. Encoder nén dữ liệu thành latent vector có số chiều thấp hơn.

- + **Bước 3 – Giải mã (Decoder):** Latent vector được đưa qua decoder để tái tạo lại vector đầy đủ. Decoder có cấu trúc đối xứng với encoder.
- + **Bước 4 – Tính hàm mất mát:** Hàm mất mát Mean Squared Error (MSE) được tính giữa output của decoder và target (vector đầy đủ) theo công thức (3.6).
- + **Bước 5 – Cập nhật trọng số:** Bộ tối ưu Adam cập nhật trọng số của encoder và decoder để giảm MSE loss.
- + **Bước 6 – Lặp lại:** Các bước 1-5 được lặp lại qua 100 epochs trên toàn bộ tập huấn luyện.
- **Kiến trúc riêng từng biến thể:**
 - + **VGG-DAE:** Conv1D với 3 lớp, input 12.288 chiều
 - + **CLIP-DAE:** MLP (1536 $\rightarrow$ 1024 $\rightarrow$ 512 $\rightarrow$ 256 $\rightarrow$ 512 $\rightarrow$ 1024 $\rightarrow$ 1536) + Dropout(0,2)
 - + **Text-DAE:** MLP (1152 $\rightarrow$ 768 $\rightarrow$ 384 $\rightarrow$ 192 $\rightarrow$ 384 $\rightarrow$ 768 $\rightarrow$ 1152) + Dropout(0,2)

3.4.3. Kết quả huấn luyện các DAE

Bảng 3. 8 Kết quả huấn luyện ba biến thể DAE

Biến thể	Final Train Loss	Cosine similarity (reconstruct)	Ghi chú
VGG-DAE	0,0234	$\sim 0,326$	Số chiều quá cao, reconstruct kém
CLIP-DAE	0,0087	$\sim 0,921$	Tốt nhất
Text-DAE	0,0092	$\sim 0,908$	Tốt

Nhận xét:

- VGG-DAE có cosine similarity rất thấp ($\sim 0,326$), nguyên nhân do đặc trưng VGG-19 có số chiều 4096 quá lớn so với số lượng dữ liệu huấn luyện (2.202 items), dẫn đến hiện tượng "curse of dimensionality". Mô hình không thể học được phân phối đặc trưng một cách hiệu quả.

- CLIP-DAE đạt cosine similarity $\sim 0,921$, cao nhất trong ba biến thể. Điều này chứng tỏ đặc trưng CLIP với 512 chiều là phù hợp cho bài toán, vừa đủ để biểu diễn thông tin thị giác vừa không gây quá tải cho mô hình DAE.
- Text-DAE đạt cosine similarity $\sim 0,908$, chỉ thấp hơn CLIP-DAE một chút. Điều này cho thấy đặc trưng văn bản từ title sản phẩm cũng mang nhiều thông tin hữu ích về phong cách và loại sản phẩm.

3.5 Xây dựng và đánh giá các mô hình Hybrid

3.5.1. Bốn phương pháp Hybrid

Bảng 3. 9 Bốn phương pháp gợi ý được triển khai

Phương pháp	Các thành phần	Kỹ thuật kết hợp
LFM only	ELFMImproved	Không (chỉ dùng ELFMImproved)
VGG Hybrid	ELFMImproved + VGG-DAE	RRF
CLIP Hybrid	ELFMImproved + CLIP-DAE	RRF
CLIP+Text Hybrid	ELFMImproved + CLIP-DAE + Text-DAE	RRF

3.5.2. Quá trình kết hợp Hybrid bằng RRF

- **Quá trình kết hợp các mô hình hybrid được thực hiện theo các bước sau:**
 - + **Bước 1 – Chạy từng phương pháp thành phần:** Với mỗi cặp (top, bottom) trong tập test, hệ thống chạy ELFMImproved và các DAE tương ứng. Mỗi phương pháp trả về danh sách các giấy candidate kèm theo thứ hạng (rank) từ 1 đến 300.
 - + **Bước 2 – Tính RRF score:** Với mỗi giấy candidate s , hệ thống tính RRFscore theo công thức (2.7) đã trình bày tại Chương 2. Công thức này tính tổng nghịch đảo của $(k + \text{rank})$ trên tất cả các phương pháp thành phần, với $k = 60$.

- + **Bước 3 – Xếp hạng tổng hợp:** Các giày candidate được sắp xếp theo RRFscore giảm dần (giá trị càng cao càng phù hợp). Danh sách top-K được lấy làm kết quả gợi ý cuối cùng.
- **Ví dụ minh họa:** Với một test case cụ thể, giả sử có 4 đôi giày candidate. ELFMImproved xếp hạng lần lượt là (S1:1, S2:2, S3:3, S4:4). CLIP-DAE xếp hạng lần lượt là (S1:3, S2:2, S3:1, S4:4). RRFscore được tính như sau:
 - + **S1:** $1/(60+1) + 1/(60+3) = 0,0164 + 0,0159 = 0,0323$
 - + **S2:** $1/(60+2) + 1/(60+2) = 0,0161 + 0,0161 = 0,0322$
 - + **S3:** $1/(60+3) + 1/(60+1) = 0,0159 + 0,0164 = 0,0323$
 - + **S4:** $1/(60+4) + 1/(60+4) = 0,0156 + 0,0156 = 0,0312$
- **Kết quả:** S1 và S3 cùng có RRFscore cao nhất (0,0323), S2 đứng thứ hai (0,0322), S4 thấp nhất (0,0312).

3.5.3. Thiết lập thực nghiệm đánh giá

Bảng 3. 10 Cấu hình thực nghiệm đánh giá

Tham số	Giá trị
Train/Test split	90/10 trên triplets
Số candidate shoes	300 (1 ground truth + 299 random)
Số test cases	200
Chỉ số đánh giá	Precision@K, Recall@K, Accuracy@K
Giá trị K	10, 15, 20

3.5.4. Kết quả thực nghiệm

Bảng 3. 11 Kết quả của bốn phương pháp gợi ý

Phương pháp	Accuracy@10	Accuracy@15	Accuracy@20
LFM only	-	-	-
VGG Hybrid	~5-7%	~5-7%	~5-7%
CLIP Hybrid	45,5%	50,5%	55,0%
CLIP+Text Hybrid	79,0%	84,5%	85,5%

3.5.5. Phân tích kết quả

– **So sánh CLIP Hybrid với VGG Hybrid:**

CLIP Hybrid đạt $\text{Accuracy}@10 = 45,5\%$, cao hơn rất nhiều so với VGG Hybrid (chỉ khoảng 5-7%). Sự chênh lệch lớn này đến từ hai nguyên nhân chính:

- + **Thứ nhất**, đặc trưng VGG-19 có số chiều 4096, quá cao so với số lượng dữ liệu huấn luyện (2.202 items). Điều này dẫn đến hiện tượng "curse of dimensionality", khiến VGG-DAE không thể học được phân phối đặc trưng một cách hiệu quả. Cosine similarity giữa đầu vào và đầu ra reconstruct chỉ đạt $\sim 0,326$.
- + **Thứ hai**, đặc trưng CLIP với 512 chiều có kích thước phù hợp hơn nhiều. CLIP-DAE đạt cosine similarity $\sim 0,921$, gần gấp ba lần so với VGG-DAE. Nhờ đó, CLIP Hybrid có thể dự đoán giày chính xác hơn đáng kể.

– **So sánh CLIP+Text Hybrid với CLIP Hybrid:**

CLIP+Text Hybrid đạt $\text{Accuracy}@10 = 79,0\%$, cao hơn 33,5% so với CLIP Hybrid (45,5%). Sự cải thiện này đến từ việc bổ sung đặc trưng văn bản (Text-DAE). Cụ thể:

- + Text-DAE trích xuất đặc trưng từ title sản phẩm (ví dụ: "Men's Casual Denim Jeans", "Women's Running Shoes"), cung cấp thông tin về phong cách (casual, formal), chất liệu (denim, leather), và mục đích sử dụng (running, walking).
- + Các thông tin này bổ sung cho đặc trưng thị giác từ CLIP, giúp hệ thống hiểu rõ hơn về ngữ nghĩa của sản phẩm. Khi kết hợp cả hai nguồn thông tin qua RRF, kết quả gợi ý được cải thiện đáng kể.

– **Tóm tắt nguyên nhân thành công và thất bại:**

Bảng 3. 12 Nguyên nhân thành công/thất bại của các phương pháp

Phương pháp	Kết quả	Nguyên nhân chính
VGG Hybrid	Kém ($\sim 5-7\%$)	Số chiều VGG-19 quá cao (4096), DAE reconstruct kém (cosine similarity $\sim 0,326$)

CLIP Hybrid	Khá (45,5%)	Số chiều CLIP phù hợp (512), DAE reconstruct tốt (cosine similarity ~0,921)
CLIP+Text Hybrid	Tốt nhất (79,0%)	Kết hợp cả thị giác (CLIP) và văn bản (Text), hai nguồn thông tin bổ trợ lẫn nhau

– **Đánh giá tổng thể:**

Kết quả thực nghiệm cho thấy mô hình **CLIP+Text Hybrid** là tốt nhất với $Accuracy@10 = 79,0\%$, $Accuracy@15 = 84,5\%$, $Accuracy@20 = 85,5\%$. Điều này chứng tỏ việc kết hợp đa phương thức (thị giác từ CLIP và văn bản từ title) mang lại hiệu quả vượt trội so với chỉ sử dụng một loại đặc trưng. Đồng thời, kết quả cũng chỉ ra rằng việc lựa chọn đặc trưng thị giác phù hợp (CLIP thay vì VGG) đóng vai trò then chốt trong thành công của hệ thống.

3.6 Xây dựng hệ thống gợi ý thời trang


Hệ thống gợi ý thời trang StyleAI được xây dựng nhằm cung cấp cho người dùng các đề xuất giày phù hợp dựa trên cặp áo (top) và quần (bottom) đã chọn. Hệ thống sử dụng React làm nền tảng giao diện web, FastAPI làm backend, SQL Server làm cơ sở dữ liệu, tích hợp các mô hình gợi ý như CLIP Hybrid và CLIP+Text Hybrid. Phần này sẽ trình bày chi tiết về thiết kế giao diện, luồng hoạt động và triển khai hệ thống.

3.6.1. Thiết kế giao diện

Frontend: Giao diện người dùng được xây dựng bằng React 18.2.0 kết hợp với Vite 5.1.0. Giao diện được thiết kế với phong cách hiện đại, sử dụng font chữ DM Sans và bảng màu vàng gold chủ đạo (nền #FFF7C5, màu nhấn #c9a96e) để đảm bảo trải nghiệm người dùng trực quan và thân thiện. Các thành phần chính của giao diện bao gồm:

a) Trang đăng nhập

- **Chức năng:** Cho phép người dùng đăng nhập vào hệ thống với email và mật khẩu. Nếu chưa có tài khoản, người dùng có thể sử dụng các tài khoản demo được cung cấp sẵn.
- **Giao diện:**
 - + Cột trái: logo "STYLEAI", headline "Hệ Thống Gợi Ý Thời Trang AI", mô tả hệ thống, danh sách công nghệ (E-LFM, VGG-DAE, CLIP-DAE, Weighted RRF, SQL Server), sơ đồ kiến trúc mini.
 - + Cột phải: form đăng nhập với hai trường email và mật khẩu (mật khẩu được ẩn khi nhập).
 - + Nút đăng nhập màu vàng gold, liên kết đến các tài khoản demo.
- **Tài khoản demo:**
 - + Admin: admin@fashion.ai / Admin@123
 - + Staff: staff@fashion.ai / Staff@123
 - + Customer: customer@fashion.ai / Customer@123




Hình 3. 2 Giao diện trang đăng nhập


b) Trang khách hàng (CustomerHome)

- **Chức năng:** Cho phép khách hàng chọn áo (top) và quần (bottom) từ danh sách sản phẩm, sau đó gửi yêu cầu gợi ý giày. Hệ thống trả về danh sách giày phù hợp nhất.
- **Giao diện:**
 - + Header cố định với logo, tên người dùng và nút đăng xuất.

- + Hai panel song song: panel trái hiển thị danh sách áo (Tops), panel phải hiển thị danh sách quần (Bottoms).
- + Mỗi panel có phân trang (Prev/Next) để duyệt qua nhiều sản phẩm.
- + Mỗi sản phẩm hiển thị ảnh và tên sản phẩm.
- + Nút "Gợi ý" màu vàng gold để gửi yêu cầu.
- + Kết quả gợi ý hiển thị dưới dạng danh sách với thứ hạng, asin, title, brand, price.




Hình 3. 3 Giao diện trang khách hàng



Hình 3. 4 Giao diện hiển thị kết quả gợi ý giày

c) Trang Staff (StaffDashboard)


- **Chức năng:** Hiển thị các chỉ số thống kê, cho phép so sánh các phương pháp gợi ý, và xem lịch sử recommendation logs.
- **Giao diện:**
 - + Hàng đầu: các metrics (Avg latency, Total triplets, Products by cat) hiển thị dạng thẻ (card).
 - + Phần so sánh phương pháp: ô nhập top_asin, bottom_asin, k; kết quả so sánh giữa các phương pháp (vgg_only, clip_only, hybrid).
 - + Phần logs: bảng hiển thị lịch sử gợi ý, có thể lọc theo method.



Hình 3. 5 Giao diện trang Staff

d) Trang Admin (AdminPanel)

- **Chức năng:** Cho phép quản lý người dùng và xem thống kê toàn hệ thống.
- **Giao diện:**
 - + Hàng đầu: các thống kê (total users, customers, staff, recommendation logs, interactions).
 - + Form tạo user mới: nhập email, password, full_name, role (admin/staff/customer).
 - + Danh sách user: hiển thị dạng bảng, có filter theo role và phân trang.
 - + Các nút hành động: sửa, xóa user.



Hình 3. 6 Giao diện trang Admin

e) Điều hướng và phân quyền

- **Chức năng:** Tự động chuyển hướng người dùng đến đúng trang dựa trên role.
- **Luồng:**
 - + Sau khi đăng nhập thành công, hệ thống đọc role từ JWT token.
 - + role = "admin" → chuyển đến /admin
 - + role = "staff" → chuyển đến /staff
 - + role = "customer" → chuyển đến /home
 - + Các route được bảo vệ: /staff chỉ dành cho staff và admin, /admin chỉ dành cho admin.

f) Màu sắc và kiểu thiết kế

Bảng 3. 13 Biến màu chính trong giao diện StyleAI

Tên biến	Mã màu	Sử dụng
--gold	#c9a96e	Màu chủ đạo, nút bấm, đường viền
--bg0	#FFF7C5	Nền toàn trang
--bg1	#fff4a8	Nền card, form
--t1	#2a1a00	Màu chữ chính
--t2	#5a4723	Màu chữ phụ
--green	#98c379	Thông báo thành công
--red	#e06c75	Thông báo lỗi

--blue	#61afef	Liên kết
--------	---------	----------

3.6.2. Backend

Hệ thống backend xử lý các yêu cầu từ người dùng và tích hợp các mô hình gợi ý. Các thành phần chính bao gồm:

a) Xử lý yêu cầu người dùng

- **Đăng nhập/Xác thực:** Xác thực thông tin người dùng qua bảng users trong SQL Server, tạo và trả về JWT token (HS256, có thời hạn).
- **Lấy danh sách sản phẩm:** Lọc sản phẩm theo category (Tops/Bottoms/Shoes), hỗ trợ tìm kiếm theo title/brand, phân trang.
- **Gợi ý giày:** Nhận top_asin và bottom_asin, tính toán similarity, trả về top-K giày phù hợp.
- **Ghi log:** Lưu thông tin gợi ý vào bảng recommendation_logs (user_id, top_asin, bottom_asin, method, k, results, latency_ms).
- **Ghi tương tác:** Lưu hành động của người dùng (view, like, purchase) vào bảng interactions.

b) Tích hợp mô hình gợi ý

- **Mô hình dựa trên VGG (vgg_only):** Sử dụng đặc trưng VGG-19 (4096 chiều) từ bảng product_features_vgg, tính cosine similarity.
- **Mô hình dựa trên CLIP (clip_only):** Sử dụng đặc trưng CLIP (512 chiều) từ bảng product_features_clip, tính cosine similarity.
- **Mô hình hybrid (clip_vgg_hybrid):** Kết hợp cả VGG và CLIP bằng Weighted RRF (Reciprocal Rank Fusion), có thể điều chỉnh trọng số.

c) Các module backend

Bảng 3. 14 Các module backend và chức năng

Module	Chức năng
main.py	Entry point, CORS, include routers
database.py	Kết nối SQL Server qua SQLAlchemy + pyodbc
auth.py	Xác thực JWT, Bcrypt hash, login/logout

permissions.py	Phân quyền (get_current_user, require_staff, require_admin)
products.py	CRUD sản phẩm, lọc theo category, search, pagination
recommend.py	Tính similarity, gợi ý giày, ghi logs
staff.py	Dashboard metrics, so sánh methods, xem logs
admin.py	Quản lý user, thống kê hệ thống

d) Quản lý lỗi và ghi log

- Hệ thống ghi log các sự kiện quan trọng (đăng nhập, gợi ý, lỗi database) vào file log.
- Xử lý lỗi kết nối database, lỗi thiếu feature cache, hiển thị thông báo chi tiết.

3.6.3. Luồng hoạt động

a) Khởi tạo hệ thống

- **Kiểm tra môi trường:**
 - + Kiểm tra kết nối SQL Server (DB_SERVER, DB_NAME, DB_USER, DB_PASSWORD).
 - + Kiểm tra sự tồn tại của các bảng (users, products, product_features_vgg, product_features_clip).
 - + Kiểm tra dữ liệu mẫu (ít nhất có sản phẩm thuộc các category Tops, Bottoms, Shoes).
- **Tải dữ liệu và feature cache:**
 - + Tải feature VGG và CLIP từ database vào cache (dictionary) để tăng tốc độ tính toán.
 - + Tải danh sách candidate shoes (main_cat = "Shoes" và has_vgg = True).

b) Đăng nhập/Phân quyền

- **Đăng nhập:**
 - + Người dùng nhập email và mật khẩu.
 - + Hệ thống kiểm tra thông tin trong bảng users của SQL Server.

- + Nếu hợp lệ, tạo JWT token (HS256) và trả về cho client.
- + Client lưu token vào localStorage (key: sa_token).
- **Phân quyền và chuyển hướng:**
 - + Dựa vào role trong token, hệ thống chuyển hướng:
 - + admin → /admin
 - + staff → /staff
 - + customer → /home

c) Trang khách hàng (CustomerHome)

- **Chọn sản phẩm:**
 - + Người dùng chọn top từ panel trái.
 - + Người dùng chọn bottom từ panel phải.
 - + Hệ thống hiển thị ảnh và tên sản phẩm đã chọn.
- **Gửi yêu cầu gợi ý:**
 - + Người dùng nhấn nút "Gợi ý".
 - + Hệ thống gửi POST /api/recommend/ với payload {top_asin, bottom_asin, k=10}.
 - + Backend tính cosine similarity và trả về danh sách giày top-K.
 - + Frontend hiển thị kết quả (rank, asin, title, brand, price).

d) Trang Staff (StaffDashboard)

- **Xem metrics:**
 - + Gọi GET /api/staff/dashboard để lấy Avg latency, Total triplets, Products by category.
 - + Hiển thị dạng thẻ (card).
- **So sánh methods:**
 - + Nhập top_asin, bottom_asin, k.
 - + Gọi POST /api/recommend/compare.
 - + Hiển thị kết quả so sánh giữa vgg_only, clip_only, hybrid.
- **Xem logs:**
 - + Gọi GET /api/staff/recommendation-logs (có thể lọc theo method).
 - + Hiển thị bảng logs.

e) Trang Admin (AdminPanel)

- **Xem thống kê:** Gọi GET /api/admin/stats để lấy total users, customers, staff, logs, interactions.
- **Quản lý user:**
 - + Gọi GET /api/admin/users để lấy danh sách user (có filter role, phân trang).
 - + Form tạo user mới: POST /api/admin/users.
 - + Sửa/xóa user: PATCH/DELETE /api/admin/users/{user_id}.

f) Đăng xuất

- Xóa token khỏi localStorage.
- Chuyển hướng về trang đăng nhập (/login).

3.6.4. Triển khai

Môi trường:

- **Công cụ:** Frontend chạy trên Node.js (React + Vite), backend chạy trên Python (FastAPI), database trên SQL Server.
- **Thư viện chính:**
 - + Frontend: React 18.2.0, React Router DOM 6.22.0, Recharts 2.12.0, Axios.
 - + Backend: FastAPI, SQLAlchemy, pyodbc, Bcrypt, PyJWT.

Yêu cầu phần cứng:

- Máy tính cá nhân với CPU đủ mạnh để chạy Node.js và Python đồng thời.
- SQL Server (có thể chạy local hoặc remote).
- Dung lượng đĩa đủ để lưu trữ dữ liệu sản phẩm (~500MB) và feature cache (~200MB).

Lưu trữ:

- **Dữ liệu sản phẩm:**
 - + Bảng products lưu thông tin sản phẩm (asin, title, brand, price, img_url, main_cat).
 - + Bảng product_features_vgg lưu đặc trưng VGG (4096 chiều dạng JSON).
 - + Bảng product_features_clip lưu đặc trưng CLIP (512 chiều dạng JSON).
- **Dữ liệu người dùng:**
 - + Bảng users lưu thông tin người dùng (id, email, password_hash, full_name, role, is_active).

- + Bảng sessions lưu phiên đăng nhập (token_hash, ip_address, user_agent, expires_at).
- **Dữ liệu tương tác và log:**
 - + Bảng interactions lưu hành động người dùng (user_id, asin, action, session_id).
 - + Bảng recommendation_logs lưu lịch sử gợi ý (user_id, top_asin, bottom_asin, method, k, results, latency_ms).

Quy trình triển khai:

a) Cài đặt môi trường backend:

- Cài đặt Python 3.9+ và các thư viện (pip install -r requirements.txt).
- Cấu hình kết nối SQL Server qua biến môi trường (DB_SERVER, DB_NAME, DB_USER, DB_PASSWORD).
- Chạy backend: uvicorn main:app --reload --port 8000

b) Cài đặt môi trường frontend:

- Cài đặt Node.js 18+ và các thư viện (npm install).
- Cấu hình API endpoint trong file .env (VITE_API_URL=<http://localhost:8000>).
- Chạy frontend: npm run dev

c) Chuẩn bị dữ liệu:

- Chạy script SQLQuery1.sql để tạo database và các bảng.
- Import dữ liệu sản phẩm và features vào database.
- Seed dữ liệu người dùng mặc định (admin, staff, customer).

d) Chạy ứng dụng:

- Backend chạy tại <http://localhost:8000>
- Frontend chạy tại <http://localhost:3000>
- Truy cập frontend qua trình duyệt.

e) Kiểm tra và xử lý lỗi:

- Kiểm tra kết nối database trước khi khởi động.
- Kiểm tra sự tồn tại của feature cache (VGG, CLIP) trong database.
- Hiển thị thông báo lỗi chi tiết nếu thiếu dữ liệu hoặc kết nối thất bại.

3.6.5. Tổng kết chương 3

Chương 3 đã trình bày chi tiết quá trình xây dựng hệ thống gợi ý phối đồ thời trang StyleAI, từ thu thập và xử lý dữ liệu, phát triển các mô hình gợi ý, đến triển khai hệ thống trên nền tảng web sử dụng React và FastAPI. Các nội dung chính được tóm tắt như sau:

a, Thu thập và xử lý dữ liệu:

- Bộ dữ liệu Amazon Clothing, Shoes & Jewelry với 1,5 triệu sản phẩm, 2.669 triplets gốc (top, bottom, shoe) và các đặc trưng đã trích xuất (VGG-19 4096 chiều, CLIP 512 chiều) được sử dụng.
- Quy trình xử lý dữ liệu bao gồm: phân loại sản phẩm thành Tops, Bottoms, Shoes bằng rule-based; tăng cường dữ liệu từ quan hệ also_bought (từ 2.669 lên 324.418 triplets); lọc giữ lại 2.202 items có đầy đủ features; và chia train/test theo tỷ lệ 90/10.

b, Xây dựng và đánh giá mô hình gợi ý:

- Bốn mô hình gợi ý đã được phát triển và so sánh: LFM only, VGG Hybrid, CLIP Hybrid, và CLIP+Text Hybrid.
- ELFMImproved (mô hình hành vi cải tiến) đạt validation accuracy 87,2% sau 30 epochs, với embedding dimension 100, dropout 0,1, negative sampling tỷ lệ 4:1.
- CLIP-DAE đạt cosine similarity 0,921, vượt trội so với VGG-DAE (chỉ 0,326) do số chiều đặc trưng phù hợp (512 so với 4096).
- Mô hình CLIP+Text Hybrid cho kết quả tốt nhất với $\text{Accuracy}@10 = 79,0\%$, $\text{Accuracy}@15 = 84,5\%$, $\text{Accuracy}@20 = 85,5\%$, nhờ kết hợp cả đặc trưng thị giác (CLIP) và đặc trưng văn bản (Sentence-Transformers).
- VGG Hybrid cho kết quả kém nhất (~5-7%) do VGG features 4096 chiều quá cao, dẫn đến DAE reconstruct kém.

c, Triển khai hệ thống gợi ý thời trang:

- Hệ thống được xây dựng với frontend bằng React + Vite, backend bằng FastAPI, cơ sở dữ liệu SQL Server. Giao diện sử dụng font DM Sans và bảng màu vàng gold chủ đạo.
- Các trang chính bao gồm: trang đăng nhập (có tài khoản demo), trang khách hàng (chọn top/bottom và nhận gợi ý giày), trang staff (xem metrics, so sánh methods, logs), và trang admin (quản lý user, thống kê).

- Backend tích hợp ba phương thức gợi ý: vgg_only, clip_only, và clip_vgg_hybrid (Weighted RRF), sử dụng JWT cho xác thực và phân quyền (admin, staff, customer).
- API bao gồm các nhóm: auth, products, recommend, staff, admin. Hệ thống ghi log gợi ý vào bảng recommendation_logs và tương tác người dùng vào bảng interactions.
- Hệ thống được triển khai cục bộ trên localhost, frontend chạy cổng 3000, backend chạy cổng 8000, yêu cầu Node.js, Python 3.9+, SQL Server.

d, Hướng phát triển:

- **Cải thiện dữ liệu:** Mở rộng số lượng triplets lên tương đương paper gốc (~70.000) để cải thiện độ chính xác, tích hợp thêm thông tin sản phẩm (chất liệu, thương hiệu, mùa vụ).
- **Tối ưu mô hình:** Thử nghiệm các mô hình mới hơn như GNN (Graph Neural Networks) cho bài toán phối đồ, Diffusion Models cho sinh outfit, và Large Multimodal Models (LMMs) để tăng khả năng hiểu ngữ nghĩa thời trang.
- **Mở rộng hệ thống:** Triển khai hệ thống trên cloud (AWS, Azure) để hỗ trợ nhiều người dùng, tích hợp tính năng gợi ý theo thời gian thực và phân tích phản hồi người dùng.
- **Nâng cao trải nghiệm người dùng:** Thêm tính năng cá nhân hóa theo lịch sử mua sắm của từng user, hỗ trợ gợi ý theo ngữ cảnh (thời tiết, sự kiện), và tối ưu giao diện trên thiết bị di động.
- **Tăng hiệu suất:** Tối ưu feature cache, sử dụng Approximate Nearest Neighbors (ANN) thay vì tính similarity toàn bộ để giảm thời gian gợi ý, đáp ứng yêu cầu real-time.

Chương 3 đã đặt nền tảng vững chắc cho hệ thống gợi ý phối đồ thời trang StyleAI với các mô hình hiệu quả (đặc biệt là CLIP+Text Hybrid đạt 79% Accuracy@10) và giao diện web thân thiện, phù hợp với ba vai trò người dùng khác nhau.

KẾT LUẬN

Qua quá trình thực hiện đồ án tốt nghiệp “Fashion Coordinates Recommendation System – Hệ thống gợi ý phối đồ thời trang dựa trên hành vi người dùng và đặc trưng hình ảnh”, đề tài đã nghiên cứu và phát triển thành công một hệ thống gợi ý phối đồ hoàn chỉnh, ứng dụng các kỹ thuật học máy và học sâu tiên tiến. Đồ án không chỉ thể hiện sự kết hợp giữa lý thuyết và thực hành mà còn đóng góp vào việc giải quyết bài toán thực tiễn "Complete the Look" trong lĩnh vực thời trang. Các kết quả chính đạt được bao gồm:

Xây dựng và đánh giá bốn mô hình gợi ý:

- **ELFMImproved** (mô hình hành vi cải tiến) đạt validation accuracy 87,2% sau 30 epochs, với embedding dimension 100, dropout 0,1, negative sampling tỷ lệ 4:1, vượt trội so với LFM gốc nhờ bổ sung bias, dropout và optimizer Adam.
- **CLIP+Text Hybrid** đạt kết quả tốt nhất với $\text{Accuracy}@10 = 79,0\%$, $\text{Accuracy}@15 = 84,5\%$, $\text{Accuracy}@20 = 85,5\%$, nhờ kết hợp cả ba loại đặc trưng: hành vi (ELFMImproved), thị giác (CLIP) và văn bản (Sentence-Transformers).
- **CLIP Hybrid** đạt $\text{Accuracy}@10 = 45,5\%$, cao hơn đáng kể so với VGG Hybrid (chỉ $\sim 5-7\%$), chứng minh rằng việc lựa chọn đặc trưng thị giác ảnh hưởng lớn đến hiệu suất. VGG features 4096 chiều quá cao dẫn đến DAE reconstruct kém (cosine similarity $\sim 0,326$), trong khi CLIP features 512 chiều cho kết quả tốt (cosine similarity $\sim 0,921$).

Triển khai hệ thống web demo StyleAI:

- Hệ thống được xây dựng với frontend bằng React + Vite, backend bằng FastAPI, cơ sở dữ liệu SQL Server, hỗ trợ ba vai trò: admin, staff, customer.
- Tích hợp ba phương thức gợi ý: vgg_only, clip_only, và clip_vgg_hybrid (Weighted RRF) với cơ chế cache feature từ database để tối ưu tốc độ.
- Các tính năng chính bao gồm: đăng nhập/phân quyền, chọn top/bottom và nhận gợi ý giày, staff dashboard (metrics, so sánh methods, logs), admin panel (quản lý user, thống kê), đáp ứng tốt nhu cầu thực tế.

Ưu điểm:

- Hệ thống cung cấp các gợi ý phối đồ chính xác, giải quyết bài toán "Complete the Look" với $\text{Accuracy}@10$ đạt 79,0% trên mô hình tốt nhất.

- Giao diện web thân thiện, dễ sử dụng, được phân quyền rõ ràng cho từng vai trò (admin, staff, customer).
- Các mô hình được cải tiến (ELFMImproved, CLIP-DAE, Text-DAE) và kỹ thuật kết hợp RRF giúp tận dụng tối đa cả ba nguồn thông tin: hành vi người dùng, đặc trưng thị giác và đặc trưng văn bản.

Hạn chế:

- Số lượng triplets gốc còn nhỏ (2.669), chỉ bằng khoảng 1/17 so với các nghiên cứu tham khảo (khoảng 70.000), ảnh hưởng đến khả năng tổng quát hóa của mô hình.
- VGG-DAE cho hiệu suất kém do số chiều đặc trưng quá cao, dẫn đến lãng phí tài nguyên tính toán.
- Hệ thống hiện chưa tích hợp yếu tố cá nhân hóa theo lịch sử mua sắm của từng người dùng, mới chỉ dừng lại ở gợi ý dựa trên cặp (top, bottom).
- Hệ thống chỉ triển khai cục bộ, chưa hỗ trợ xử lý thời gian thực hoặc phục vụ lượng lớn người dùng đồng thời.

Hướng phát triển trong tương lai:

- **Cải thiện dữ liệu:** Mở rộng số lượng triplets lên tương đương các nghiên cứu tham khảo (~70.000) để cải thiện độ chính xác, tích hợp thêm thông tin sản phẩm (chất liệu, thương hiệu, mùa vụ).
- **Tối ưu hóa hiệu suất mô hình:** Thử nghiệm các mô hình mới hơn như GNN (Graph Neural Networks) cho bài toán phối đồ, Diffusion Models cho sinh outfit, và Large Multimodal Models (LMMs) để tăng khả năng hiểu ngữ nghĩa thời trang. Đồng thời áp dụng kỹ thuật Approximate Nearest Neighbors (ANN) để giảm thời gian gợi ý.
- **Triển khai trên nền tảng đám mây:** Đưa hệ thống lên các nền tảng như AWS, Azure hoặc Heroku để hỗ trợ xử lý thời gian thực và phục vụ số lượng lớn người dùng, đảm bảo tính mở rộng.
- **Phát triển tính năng nâng cao:** Tích hợp cá nhân hóa theo lịch sử mua sắm của từng user, gợi ý theo ngữ cảnh (thời tiết, sự kiện, mùa vụ), hỗ trợ đa ngôn ngữ, và tối ưu giao diện trên thiết bị di động để nâng cao trải nghiệm người dùng, hướng tới ứng dụng thực tế trong các nền tảng thương mại điện tử thời trang.

- **Tăng hiệu suất:** Tối ưu feature cache, sử dụng mixed-precision training để giảm thời gian huấn luyện, và triển khai hệ thống real-time với khả năng phản hồi nhanh cho người dùng.

Đồ án đã đặt nền tảng vững chắc cho hệ thống gợi ý phối đồ thời trang với các mô hình hiệu quả (đặc biệt là CLIP+Text Hybrid đạt 79% Accuracy@10) và giao diện web thân thiện, mở ra nhiều hướng phát triển trong tương lai để ứng dụng vào thực tế.

TÀI LIỆU THAM KHẢO

- [1] GU, S. et al. (2017). Fashion coordinates recommendation based on user behavior and visual clothing style. ICCIP 2017, Tokyo, Japan.
- [2] KACHBAL, I. et al. (2025). Fashion recommendation systems: A comprehensive analysis of evolution from single items to complete outfits. IJ CEDS 2025.
- [3] SABITHA, R.; SUNDAR, D. (2025). A fashion product recommendation based on adaptive VPKNN-NET algorithm without fuzzy similar image. Frontiers in Data Science 2025.
- [4] RADFORD, A. et al. (2021). Learning transferable visual models from natural language supervision. ICML 2021.
- [5] SIMONYAN, K.; ZISSERMAN, A. (2014). Very deep convolutional networks for large-scale image recognition. ICLR 2015.
- [6] VINCENT, P. et al. (2008). Extracting and composing robust features with denoising autoencoders. ICML 2008, ACM.
- [7] HE, R.; McAULEY, J. (2016). VBPR: Visual Bayesian personalized ranking for implicit feedback. AAAI 2016.
- [8] WANG, X. et al. (2021). Local factor models for large-scale inductive recommendation. RecSys 2021, ACM.
- [9] SEDHAINI, S. et al. (2015). AutoRec: Autoencoders meet collaborative filtering. WWW 2015, ACM.
- [10] REIMERS, N.; GUREVYCH, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. EMNLP 2019.